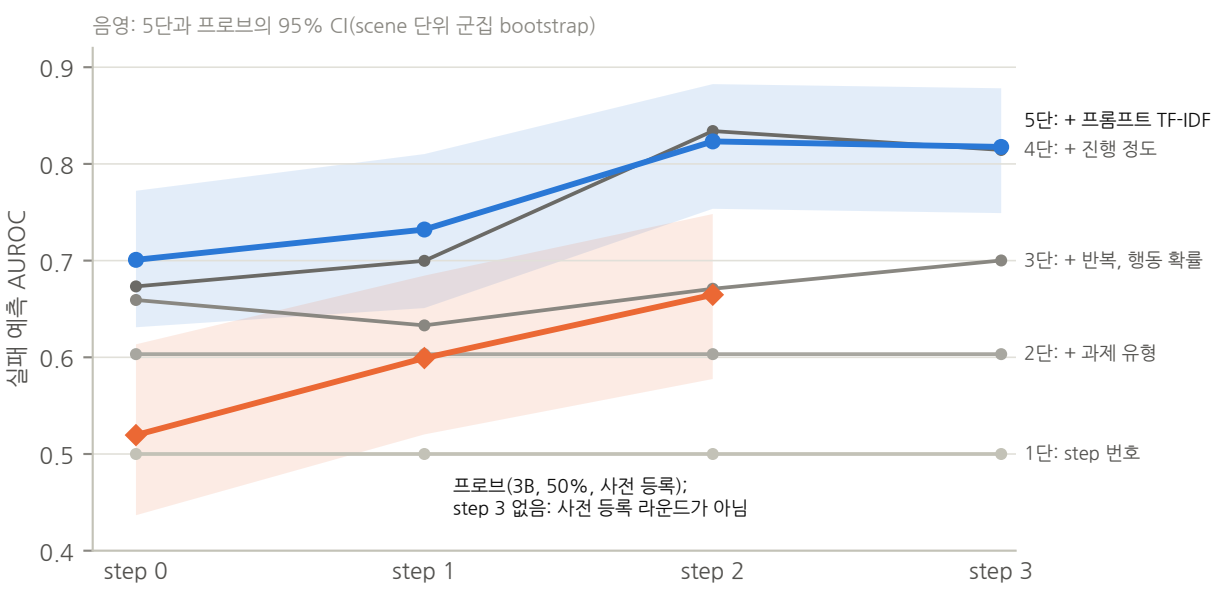
음영: 5단과 프로브의 95% CI(scene 단위 군집 bootstrap)
실패 예측 AUROC
0.9
0.8
0.7
0.6
0.5
0.4
step 0
step 1
step 2
step 3
5단: + 프롬프트 TF-IDF
4단: + 진행 정도
3단: + 반복, 행동 확률
2단: + 과제 유형
1단: step 번호
프로브(3B, 50%, 사전 등록);
step 3 없음: 사전 등록 라운드가 아님