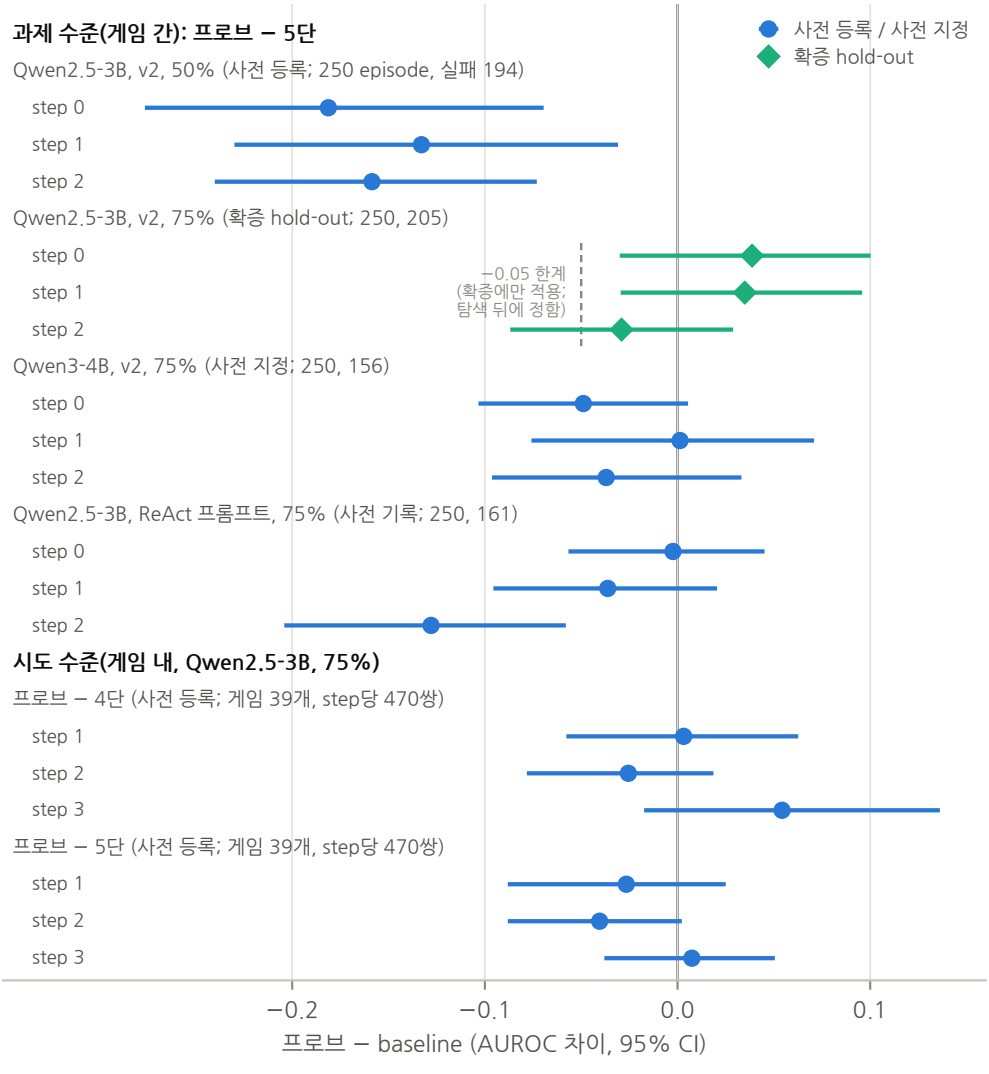
과제 수준(게임 간): 프로브 – 5단
사전 등록 / 사전 지정
확증 hold-out
Qwen2.5-3B, v2, 50% (사전 등록; 250 episode, 실패 194)
step 0
step 1
step 2
Qwen2.5-3B, v2, 75% (확증 hold-out; 250, 205)
step 0
step 1
step 2
−0.05 한계
(확증에만 적용;
탐색 뒤에 정함)
Qwen3-4B, v2, 75% (사전 지정; 250, 156)
step 0
step 1
step 2
Qwen2.5-3B, ReAct 프롬프트, 75% (사전 기록; 250, 161)
step 0
step 1
step 2
시도 수준(게임 내, Qwen2.5-3B, 75%)
프로브 – 4단 (사전 등록; 게임 39개, step당 470쌍)
step 1
step 2
step 3
프로브 – 5단 (사전 등록; 게임 39개, step당 470쌍)
step 1
step 2
step 3
−0.2
−0.1
0.0
0.1
프로브 – baseline (AUROC 차이, 95% CI)