소형 Qwen 언어모델 에이전트의 실패 예측: 겉보기 정보를 넘지 못한 hidden state 프로브

저자 정보는 심사를 위해 생략

초안, October 24, 2026

초록

언어모델 에이전트의 hidden state에 학습한 선형 프로브는 실패를 일찍 예측하는 값싼 모니터로 제안되었지만, 그 이득은 과제를 보지 못하는 baseline과 비교해 측정되었다. 본 연구는 ALFWorld 가정 텍스트 환경에서 30억 파라미터 Qwen2.5 에이전트를 대상으로, 이러한 프로브가 프롬프트에 보이는 정보를 넘어 실패를 예측하는지 검증했다. 게임 간 평가는 탐욕 episode 500개로, 게임 내 평가는 100개 게임을 각 8번 실행한 데이터로 했고, 프로브를 과제 유형·프롬프트 텍스트·진행도 특징으로 만든 baseline 사다리와 비교했다. 모든 데이터는 방 배치 단위로 나누었고, 주 분석은 미리 정해 한 번만 실행했다. 사전 등록한 비교(50% 깊이 프로브)에서 프로브는 처음 세 action에서 전체 baseline보다 수신자 조작 특성 곡선 아래 면적이 0.13–0.18 낮았고(95% 신뢰구간 모두 0 아래, 구간 포함률을 대략 보정하면 두 번째 action은 간신히 0 아래), 새 250개 게임에서는 우수한 action이 없었다(차이 -0.029 ~ $+0.039$, 신뢰구간 모두 0 포함). 탐욕 결과로 층화해 고른 이 표본에서 게임은 결과 분산의 69.5%를 설명했다(95% 신뢰구간 61.3–76.5%). 게임 안에서는 세 번째 action부터 프로브와 baseline 모두 실패 시도와 성공 시도를 우연보다 잘 구분했지만, 프로브는 비교 6개 중 어디에서도 우수하지 않았다. 40억 파라미터 Qwen3 에이전트와 외부 프롬프트에서도 프로브가 우수한 action은 없었고, 외부 프롬프트의 세 번째 action에서는 프로브가 baseline보다 낮았다(차이 -0.128, 95% 신뢰구간 -0.204 ~ -0.058). 성공 손실 10% 이하(사전에 정한 범위)에서 실패할 episode를 멈추는 데 쓰면, 프로브가 고정 상한보다 action을 더 아낀다는 것은 보이지 않았다(차이 -0.032, 95% 신뢰구간 -0.183 ~ $+0.119$). 탐색에서 가장 좋은 깊이의 차이는 같은 게임에서 -0.034 ~ -0.011 이었고, 학습 episode 약 400개로 500개 게임 전체에서 보면 $+0.006$(-0.024 ~ $+0.037$)이었다. 이 깊이는 앞 250개 게임에서 골랐으므로 이 값들은 프로브에 유리하며, 그 선택에서 자유로운 값은 홀드아웃 절반의 $+0.015$뿐이다. 이 설정에서 hidden state의 이득은 찾지 못했고, 홀드아웃에서 시험한 한 설정(75% 깊이)의 단일 홀드아웃 신뢰구간은 약 0.10 AUROC를 넘는 이득을 배제하지만 그보다 작은 이득은 배제하지 못한다. 따라서 에이전트 hidden state의 실패 신호에 관한 주장은 과제를 보는 baseline과 과제 내 평가로 검증해야 한다.

1 서론

언어모델 에이전트는 환경과 여러 step에 걸쳐 상호작용하며, 실패로 끝나는 episode도 성공하는 episode만큼 계산을 쓴다. 이 비용은 에이전트를 로컬에서 실행할 때 가장 크다. 소비자 기기에서 에이전트 실행은 단일 추론보다 전력, 발열, 배터리 소모를 크게 높이며, 이 에너지의 상당량이 성공하지 못한 실행에 쓰인다 [1]. 본 연구의 설정에서 Qwen2.5-3B 에이전트는 앞 250개 ALFWorld 게임의 22.4%를 풀었고(56/250, Wilson 95% CI 17.7–28.0%), 이 게임들에서 실행한 step의 89.7%가 실패 episode에서 나왔다. 실패할 episode를 일찍 멈추면 이 비용의 상당 부분을 아낄 수 있다. 다만 소형 에이전트에서는 모니터 자체도 싸야 한다. 0.6B 텍스트 모니터는 Fail-Fast의 9–31B 공개 모델 세 개에 0.1–0.6%의 계산량만 더한다 [2]. 토큰당으로는 이 모니터가 그 policy들보다 15–52배 싸다. 반면 3B actor가 읽는 토큰을 모두 읽는 별도 0.5B 모니터는 actor 계산량의 약 13–16%를 더하고, 7B 모니터는 actor의 약 2.4배가 든다. 반면 actor가 이미 계산한 hidden state를 읽는 프로브는 모델을 다시 부를 필요가 없다. 따라서 실제로 실패를 예측한다면 소형 에이전트에 가장 자연스러운 모니터 후보이다.

내부 표현으로 실패를 예측하는 연구는 질문 단위에서 시작했다. 언어모델은 질문의 답을 아는지를 예측할 수 있다 [3]. 샘플한 답들의 의미 엔트로피는 정확도를 예측하고 [4], 선형 프로브는 이

엔트로피를 단일 생성의 hidden state에서 [5], 또는 토큰을 생성하기 전 질문만으로 [6] 근사한다. Ruan 등 [7]은 프로브를 다단계 에이전트로 확장했다. 이들은 action 마지막 토큰의 hidden state에 선형 프로브를 학습해 첫 라운드부터 최종 실패를 예측할 수 있고(TextCraft에서 세 모델 중 두 모델의 라운드 1 AUC가 0.86과 0.81), 행동 특징만 쓰는 scorer보다 일관되게 강하다고 보고했다. 같은 시기에 토큰 로그확률 [1], 작은 텍스트 모니터 [2], 행동·텍스트 특징 [8]을 쓰는 조기 중단 시스템도 제안되었다.

이 보고들은 한 가지 질문을 열어 둔다. 이 신호는 현재 시도가 어떻게 진행되는지를 보여 주는가, 아니면 에이전트가 어떤 과제를 맡았는지를 보여 주는가? 네 가지 한계 때문에 답할 수 없다.

첫째, 결과는 대부분 과제가 정한다. Llama-3.1-70B를 HotpotQA에서 10회씩 반복했을 때 100문항 중 64개는 모든 회차에서 맞고 23개는 한 번도 맞지 못했으며, 선형 프로브는 회차 단위 정답을 예측하지 못했다(AUC 0.34–0.56) [9]. 우리 데이터에서는 결과 분산의 69.5%를 게임이 설명한다(95% CI 61.3–76.5%, 게임을 탐욕 결과로 층화해 골랐으므로 모집단 값은 아니다). 이 경우 과제를 합친 AUROC는 시도의 진행이 아니라 어떤 과제인지를 반영할 수 있다. Bulut [10]은 합친 AUROC가 과제 내 성분과 과제 간 성분의 가중합이며, 과제만으로 점수를 정하는 예측기는 과제 안에서 정확히 0.5라는 점을 보였다. 그는 공개된 MATH 생성 데이터에서 가장 가까운 기존 조기 구간 프로브를 재구성했고, 합친 AUROC는 0.849이지만 문제 안에서는 0.496(95% CI 0.466–0.527)에 그쳤으며, 사전 등록한 난이도 통제 검정에서도 이득이 없었다. 생성 전 활성이 모델별 난이도를 담는다는 보고도 있다 [11]. Ruan 등은 과제당 4–8개의 rollout을 모았지만 과제 내 평가나 난이도 통제는 보고하지 않았다.

둘째, 비교 대상이 약하다. [7]의 행동 scorer는 action 로그확률, 토큰 수, prefix 길이, 오류 키워드만 쓰고, 과제 문장, 관찰, 진행도는 쓰지 않는다. 우리 데이터에서는 과제 유형만으로도 첫 action 전에 AUROC 0.603이 나온다. 다른 연구에서는 관찰 텍스트의 유사도가 hidden state의 유사도보다 행동 변동을 더 잘 예측했다($r = -0.63$ 대 -0.35) [9].

셋째, [10]의 과제 내 통제는 상호작용 에이전트에 그대로 옮겨지지 않는다. 이산 action 환경에서 같은 게임의 rollout은 초반에 프롬프트가 같으므로 동점 쌍이 생기고(우리 평가 쌍의 52–70%) 도달 가능한 AUROC가 제한된다. 우리 데이터에서는 bootstrap 신뢰구간도 명목 수준보다 좁았다(포함률 80–94%, 명목 95%). [10]의 분석은 단일 생성 수학 추론이라 이 문제를 다루지 않는다.

넷째, 모니터 비용에 대한 논의는 대형 policy를 전제한다. [2]의 0.1–0.6% 비용은 9–31B policy에서 성립하며, 소비자 기기에서 도는 3B급 에이전트에서는 이 전제가 성립하지 않는다.

따라서 핵심 문제는 다음과 같다. 에이전트 hidden state의 실패 신호가 진행 중인 실패를 읽는지, 과제 난이도와 겉보기 정보를 읽는지를 기존 근거로는 구분할 수 없다. 그 결과 소형 에이전트가 쓸 수 있는 가장 값싼 모니터가 쓸모 있는지 알 수 없다.

이 구분은 무엇을 배포할지를 정한다. 프로브가 난이도만 읽는다면 과제 문장을 보는 분류기로 충분하고 모델 내부에 접근할 이유가 없다. 같은 과제 안에서 진행 중인 실패를 읽는다면 겉보기 정보가 줄 수 없는 이득이 있다. 같은 구분이 프로브가 조기 중단에 쓸 만한지도 정한다.

그래서 우리는 작은 ALFWorld 에이전트 [12]의 hidden state 실패 예측을 각 한계에 대응하는 통제 아래에서 평가했다. 각 한계는 필요한 기능과 설계 요소에 다음과 같이 대응한다.

1. 난이도와 진행 중 실패를 분리한다. 평가를 두 층으로 나눴다. 과제 단위(탐욕 정책, 500게임)와 시도 단위(100게임 × 온도 1에서 8회 rollout, 게임 내 쌍 AUROC)이고, 게임 안에서 정확히 0.5가 나오는 난이도 오라클을 함께 두었다.

2. 겉보기 정보 대비 이득을 잰다. 5단 baseline 사다리(step 번호, + 과제 유형, + 반복·선택 확률, + 진행도, + 프롬프트 TF-IDF)와 비교하고, 현재 step의 정보를 뺀 시점 맞춤 변형도 두었다.

3. 게임 사이의 누수를 막는다. ALFWorld의 게임은 방 배치를 공유하므로 장면 단위로 교차적합하고 bootstrap했다. 게임 단위로 나누면 장면 정보만 담은 합성 특징에서도 AUROC가 0.97까지 부풀었다. 실제 프로브와 5단에서는 변화가 작았다(-0.006, -0.027).

4. 과제 내 통계를 에이전트에 맞게 만든다. 동점 쌍의 비율과 그에 따른 AUROC 상한을 보고하고, 동점 쌍을 뺀 보조 분석을 더하며, 라벨을 섞어 신뢰구간의 포함률을 점검했다.

5. 결과를 본 뒤의 선택을 막는다. 주 분석과 판정 규칙을 사전에 등록해 한 번만 실행했고, 탐색

뒤에 고른 설정은 새 250게임에서 확인했다.

6. 소형 에이전트 환경에 맞춘다. 프로브가 3B actor 자신의 hidden state를 추가 모델 호출 없이 읽게 했고, action은 후보 점수화로 골랐으며, actor(Qwen3-4B), 프롬프트(ReAct 원 예시 [13]), 그리고 탐색 분석으로 actor의 궤적을 읽는 reader의 크기(0.5B–7B)를 바꿨다.

프로브를 학습하기 전에 등록한 주 가설은 H1이다. 3B actor의 궤적을 3B 모델로 읽을 때, 처음 세 action에서 선형 프로브가 5단 baseline 전체보다 실패를 더 잘 예측한다(AUROC 차이의 95% CI가 0 위).

기존 방법을 그대로 쓰지 않은 이유는 세 가지이다. [7]의 프로토콜은 난이도와 겉보기 정보를 통제하지 않으며 과제 단위로 나누므로 ALFWorld에서는 장면 정보가 샌다. [10]의 문제 내 평가는 독립적인 단일 생성을 가정하므로 순차 환경에서 prefix를 공유하는 rollout을 다루지 못한다. [2]와 [1]의 텍스트 모니터는 모니터 비용이 무시될 만큼 큰 policy를 가정한다. 소형 모델은 자유 생성에서 가능한 action 목록에 없는 action을 자주 내므로, 본 연구는 가능한 후보마다 로그확률을 계산해 action을 고르고 프롬프트의 key–value 캐시를 재사용했다. 이 방식으로 12 GB GPU 한 장에서 실행할 수 있었다.

이 통제 아래에서 프로브는 겉보기 정보 baseline을 넘어서지 못했다. 사전 등록한 과제 단위 비교에서 프로브는 5단 baseline보다 낮았다(step 0–2에서 -0.181, -0.133, -0.159, 95% CI가 모두 0 아래). 확증 홀드아웃에서는 우수한 step이 없었다($+0.039$, $+0.035$, -0.029, CI가 모두 0을 포함). 같은 게임 안에서는 프로브와 baseline 모두 step 2부터 우연보다 잘 실패를 구분했지만(step 2와 3에서 프로브 AUROC 0.585, 0.619), 프로브가 우수한 경우는 6개 비교 중 하나도 없었다. 다른 actor(Qwen3-4B, 우수 0/3)와 다른 프롬프트(ReAct, 0/3, step 2는 열등)에서도 같은 양상이었다. 실패할 episode를 멈추는 데 쓰면, 성공 손실 10% 이하에서 프로브가 고정 step 상한보다 step을 더 아낀다는 것은 보이지 않았다(차이 -0.032, 95% CI $-0.183 \sim +0.119$). 다만 이 결과가 프로브와 baseline이 같다는 뜻은 아니다. 신뢰구간이 넓고(과제 단위에서 약 ± 0.06–0.10) 환경 하나와 프롬프트 두 개만 시험했다.

본 연구의 기여는 다음과 같다.

- 다단계 에이전트의 hidden state 실패 예측을 난이도 통제와 과제 내 평가로 다시 검토했고, 이 설정에서 프로브가 겉보기 정보보다 낫다는 증거를 찾지 못했다.
- 같은 분할과 같은 통계로 hidden state 프로브와 겉보기 정보 baseline 사다리를 비교한 사전 등록 결과를 제시했다.
- 과제 내 평가를 이산 action 에이전트에 적용할 때 생기는 두 문제, 즉 prefix를 공유해 생기는 동점 쌍과 명목보다 좁은 bootstrap 신뢰구간을 정량화했다.
- actor와 reader를 분리해 같은 궤적을 다른 크기의 reader로 읽어 비교했다. 이 부분은 탐색적이며 크기에 따른 단조 추세는 관찰되지 않았다.

2 관련 연구

선행 연구를 예측기가 무엇을 읽는지, 무엇과 비교했는지에 따라 나누어 살펴본다. 마지막에는 기존 프로토콜에서 무엇을 가져왔는지 밝힌다.

2.1 내부 표현으로 정답 여부를 예측하는 연구

모델 자신의 상태에서 성공이나 실패를 읽는 연구는 단일 질문 수준에서 시작했다. Kadavath 등 [3]은 제안된 답과 무관하게 모델이 질문의 답을 아는지를 나타내는 확률 P(IK)를 예측하도록 value head를 학습했다. P(IK)는 과제 사이에서 부분적으로 전이했지만 분포 밖에서는 보정이 나빴다. Kuhn 등 [4]은 샘플한 여러 답을 의미로 묶은 군집의 엔트로피로 불확실성을 정의했고, 이 값이 어휘 기반 baseline보다 정확도를 잘 예측했지만 질문마다 여러 번 생성해야 했다. Kossen 등 [5]은 단일 생성의 hidden state에 선형 프로브를 학습해 의미 엔트로피를 근사함으로써 이 비용을 없앴고, 이 프로브는 정확도를 직접 예측하는 프로브보다 분포 밖에서 더 잘 일반화했다. Moreno Cencerrado

등 [6]은 읽는 시점을 생성 전으로 옮겼다. 질문을 읽은 직후의 활성에 프로브를 학습해 7B에서 70B 모델이 곧 낼 답이 맞을지를 예측했으나, 수학 추론 질문에서는 일반화가 약해졌다. Lugoloobi 등 [11]은 생성 전 활성에 선형 프로브를 학습해 수학·코딩 과제에서 그 모델의 성공을 예측했다. 주 결과 표 15개 설정 중 14개에서 선형 프로브가 TF-IDF보다, 또 14개에서 질문 길이보다 높았고, 저자들은 모델이 사람의 난이도와 다른 모델별 난이도를 담는다고 결론지었다. 이 계열은 진실과 관련된 정보가 활성에서 선형으로 읽힌다는 근거에 기대고 있다. Burns 등 [14]은 진술과 그 부정의 참값이 논리적으로 일관되는 방향을 찾아 라벨 없는 활성에서 예·아니오 지식을 복원했고, Marks와 Tegmark [15]는 충분한 규모에서 참·거짓 진술의 표현에 선형 구조가 있으며 프로브가 데이터셋 사이에서 전이되고 그 방향이 출력에 인과적으로 관여한다고 보고했다. 최근 Ghasemabadi와 Niu [16]는 고정된 1.7B–20B 모델의 hidden state와 attention 패턴을 읽어 자기 답의 정답 여부를 예측했고, 이것이 내부 신호 baseline과 큰 외부 심사 모델보다 낫다고 보고했다. 이 연구들의 목표는 모두 질문마다 정해진다. 결과 하나이거나 여러 샘플의 집계이다. 이런 목표는 질문 응답에서는 의미가 있지만, 어려운 질문과 실패하는 시도를 구분하지 못한다.

2.2 에이전트의 hidden state 모니터

Ruan 등 [7]은 프로브를 다단계 에이전트에 적용했다. 이들은 각 action 마지막 토큰의 residual stream에 선형 프로브를 놓았고, 모델과 환경의 조합마다 층을 하나로 고정했다. 프로브는 과제 단위로 묶은 분할로 교차적합했으며, TextCraft와 WebShop에서 라운드마다 평가했다(셀당 800 episode, 1.7B–7B 에이전트 세 개). 프로브가 첫 라운드부터 최종 실패를 예측하고 행동 특징으로 만든 scorer보다 낫다고 보고했으며, 이 신호를 recall을 보장하는 중단 cascade로 바꿨다. ALFWorld는 Qwen-2.5-7B(477 rollout, 프로브 AUC 0.815)와 Qwen3-1.7B(0.764)로 경계 조건을 시험하는 데에만 쓰였다. 이들의 재생 절차와 과제 단위 평가는 우리와 가깝지만, 이들의 프로브는 생성한 action의 마지막 토큰을 읽고 우리 프로브는 후보 action을 점수화하기 전 프롬프트의 마지막 토큰을 읽는다. 그러나 행동 scorer는 action 로그확률, 토큰 수, prefix 길이, 오류 키워드만 쓴다. 과제당 4–8개의 rollout을 모았는데도 과제 내 평가나 난이도 통제는 보고하지 않았고, 저자 스스로 묶은 분할이 분포 안에 머문다고 밝혔다.

다른 에이전트 연구는 다른 목표를 hidden state에서 읽는다. Khan과 Khan [17]은 Gemma 4 E4B의 28번째 층 hidden state로 추론 열화를 감지하는 프로브 모니터를 만들었고, 측정된 추가 추론 비용은 없었다. 이 프로브는 나중에 평가에 쓰는 과제 목록에서 뽑은 대리 라벨 예시 35개로 학습되었으며, 저자들은 이를 타당성 연구로 제시한다. 1B–1.5B 모델에서는 개선이 없었다. Mehta와 Datta [9]는 같은 step에서 반복 실행 사이의 hidden state 유사도를 재어 ReAct 에이전트의 행동 안정성과 연결했다(Llama-3.1-70B, step 4에서 $r = -0.35$). 이들은 공유된 검색 근거가 상관의 많은 부분을 설명하고, 관찰 텍스트가 행동을 더 잘 예측하며, 이 지표는 정답 여부가 아니라 안정성을 가리킨다고 보고했다. 같은 연구에서 선형 프로브는 회차 단위 정답을 예측하지 못했다.

2.3 내부 상태 없는 조기 중단

두 번째 계열은 관찰 가능한 신호로 실패할 실행을 멈춘다. AgentStop [1]은 토큰 로그확률 특징에 gradient-boosted tree를 학습하고 소비자 노트북에서 에너지를 측정했다. Qwen3-30B-A3B에서는 낭비된 에너지를 15–20% 줄였고 성능 하락은 5% 미만이었다. 다만 1.7B 모델에서는 실패 실행과 성공 실행의 로그확률이 더 많이 겹쳤다. Fail-Fast [2]는 SWE-bench Verified 궤적의 텍스트 prefix로 0.6B 모델을 미세조정했다. 5% 오탐 예산에서 Qwen3.6-27B의 토큰을 20.4% 줄였고, AgentStop 변형은 12.5%, step 수만 쓰는 대조는 11.4%였다. 학습 때는 진행 정도를 맞춘 성공·실패 prefix를 짝지어 인스턴스 난이도를 통제하지만, 평가는 보류한 100개 인스턴스 × 5회 실행을 합쳐서 하며 인스턴스 내 분석은 찾지 못했다. EarlyEval [8]은 같은 아이디어를 평가 비용에 적용해, 행동·텍스트·참조 해답 특징의 분류기로 벤치마크 실행을 중단한다(step 13–26% 감소). Pan 등 [18]은 웹 에이전트에서 관찰 가능한 거시·미시 궤적 특징이 내부 신호 baseline과 견줄 만하다고 보였고, 과제 단위 교차검증을 썼다. Dubey [19]는 단계 출력의 임베딩, 토큰 수준 불확실성, 행동 메타데이터 같은 관찰 가능한 단계 기록만으로, 정상 실행으로만 학습한 모니터를 써서 에이전트 실패를 감지했다. 이 모니터들은 관찰 가능한 신호(로그확률, 텍스트, 행동)를 읽으며, 평가는 모두 과제를

합쳐서 한다. 이들 모니터가 싼 것은 큰 policy에 견줄 때뿐이다. [2]의 0.1–0.6% 비용은 공개 모델 9–31B 세 개에서 성립한다.

2.4 교락 요인으로서의 과제 난이도

합친 점수가 오도할 수 있다는 가장 강한 논거는 Bulut [10]에서 나온다. 그는 합친 AUROC가 문제 내 성분과 문제 간 성분의 가중합이며, 문제만으로 점수를 정하는 예측기는 문제 안에서 정확히 0.5라는 점을 보였다. 궤적을 읽지 않는 난이도 대리 변수가 공개된 R1 생성 19만 건에서 AUROC 0.873에 도달했다. 가장 가까운 기존 조기 구간 프로브를 재구성하면 합친 값은 0.849였지만 문제 안에서는 0.496(95% CI 0.466–0.527)이었고, 사전 등록한 검정에서도 난이도 baseline 대비 이득이 없었다. Mehta와 Datta [9]는 에이전트에서 반대편으로부터 비슷한 결론에 이르렀다. 정답 여부는 대부분 질문이 정했고(100문항 중 64개는 항상 정답, 23개는 한 번도 정답이 아님) 회차 단위 프로브는 실패했다. 두 연구는 같은 질문에 독립적으로 답하는 설정, 즉 단일 생성 [10]이나 소수의 ReAct 실행 [9]을 다룬다. 어느 쪽도 환경에서 행동하는 에이전트의 hidden state 실패 프로브를 평가하지는 않는다.

2.5 본 연구의 위치

[7]에서는 teacher-forced 재생, 라운드별 평가, 묶은 분할을 가져왔다. [10]에서는 문제 내 쌍 AUROC와 과제만으로 정해지는 baseline을 쓰는 방식을 가져왔다. [2]에서는 step 수만 쓰는 대조를 가져왔다. 여기에 소형 상호작용 에이전트에서 이 연구들에 없는 요소를 더했다. 겉보기 정보를 단계적으로 더하는 5단 baseline 사다리, 두 층(게임 간과 게임 내) 평가, 장면 단위 묶음, 이산 action 환경에서의 동점 쌍과 신뢰구간 포함률 처리, 그리고 actor 자신의 hidden state 프로브와 3B actor에 견준 비용으로 센 모니터의 비교이다.

3 방법

3.1 환경과 에이전트

ALFWorld(TextWorld 버전, `alfworld` 0.4.2)의 train 분할 3,553개 게임과 6개 과제 유형을 모두 사용했다. episode는 과제를 완수하거나 30번의 action을 마치면 끝났고, 과제를 완수하지 못한 episode를 실패(라벨 1)로 두었다. ALFWorld에는 실패로 끝나는 상태가 없으므로 실패는 시간 초과이다. 30 action 상한을 점검하려고 탐욕 실패 399개를 상한 100 action으로 다시 돌렸고(사전 등록한 규칙), 399개 중 11개가 31–100 action 사이에 성공했다(2.8%, Wilson 95% CI 1.6–4.9%). 상한이 사전 등록한 기준 5%보다 낮으므로 30 action 라벨을 유지했다(민감도 분석은 4.7절). 에이전트(actor)는 bfloat16의 Qwen2.5-3B-Instruct이다. 매 step의 프롬프트에는 고정된 시스템 메시지(규칙과 예시 episode 하나), 과제 문장, 최근 6개의 관찰–action 쌍, 현재 관찰, 최근 효과가 없었던 action, 가능한(admissible) action 목록이 들어갔다. 이 프롬프트를 v2라 부른다. v2는 직접 작성했다. 이전 버전은 ReAct [13]의 생각–행동 형식을 따랐고, 후보 점수화로 바꾸면서 생각 단계를 없애고 규칙 6줄과 직접 쓴 예시 episode 하나를 넣었다. ReAct 예시의 문장은 쓰지 않았다. 두 번째 외부 프롬프트는 4.4절에서 설명한다.

action은 자유 생성이 아니라 후보 점수화(constrained selection)로 골랐다. `help`, `inventory`, `look`을 뺀 가능한 action a마다 프롬프트 뒤에 `Action: a<|im_end|>`가 이어질 로그확률의 합을 점수로 하고, 프롬프트의 key–value 캐시를 재사용해 한 번의 배치 계산으로 구했다. 탐욕 정책은 점수가 가장 높은 action을 택했다. 샘플링 정책은 softmax(점수/T)에서 action을 뽑았고 $T = 1$이다. 즉 모델의 분포를 가능한 action 위에서 다시 정규화한 것이다. 난수 생성기는 (샘플 seed, episode 번호, step)으로 정해지므로 rollout을 재현하고 이어서 수집할 수 있다. 예비 실행에서 소형 모델이 자유 생성으로는 목록에 없는 action을 자주 냈기 때문에 자유 생성은 쓰지 않았다(부록 표 A5).

3.2 표현: actor와 reader의 분리

hidden state는 action을 점수화하기 직전인 프롬프트 마지막 토큰(`<|im_start|>assistant` 뒤의 줄바꿈으로, 모든 step에서 형태가 같은 템플릿 토큰; 다른 위치는 4.8절에서 비교)에서, 전체 층의 상대 깊이 25, 50, 75, 100% 위치에서 뽑았다(3B 모델은 9, 18, 27, 36층). 궤적을 바꾸지 않고 모델 크기만 바꾸기 위해, actor가 저장한 프롬프트를 teacher forcing으로 *reader* 모델에 통과시켰다. reader는 bfloat16의 Qwen2.5-0.5B, 1.5B, 3B-Instruct와, 12 GB GPU 메모리에 들어가는 가장 큰 모델인 4비트 NF4 가중치의 Qwen2.5-7B-Instruct(계산은 bfloat16)이다. 네 모델은 토크나이저와 chat template이 같다. 다시 토큰화한 프롬프트 길이는 모든 step에서 저장된 길이와 같았고, 확인한 5개 step에서는 3B reader가 actor의 저장된 hidden state를 그대로 재현했다. 3B 이외의 reader는 다른 모델의 궤적을 읽으므로, 이들의 결과는 자기 감시가 아니라 외부 감시에 관한 것이다. 프롬프트 마지막 토큰의 hidden state는 프롬프트의 결정적 함수이므로, 질문은 hidden state에 프롬프트 밖의 정보가 있는지가 아니라 모델의 계산이 실패와 관련된 특징을 겉보기 정보 baseline이 뽑는 것 이상으로 선형으로 읽히게 만드는지이다.

3.3 데이터

과제 수준 데이터(탐욕). 환경이 정하는 결정적 순서대로 서로 다른 게임 500개에서 탐욕 episode를 모았다. 앞 250개는 사전 등록 분석과 탐색 분석에 썼다. 250–499번 episode는 그 뒤에 수집한 확증용 홀드아웃이며, 수집 전에 정한 비교 하나에만 썼다(3.6절). reader hidden state는 앞 250개 episode에서만 추출했다.

시도 수준 데이터(샘플링). 탐욕 디코딩에서는 결과가 게임의 함수이므로, 과제 수준 라벨로는 과제 난이도와 진행 중 실패를 구분할 수 없다. 그래서 게임 100개를 샘플링 정책으로 각 8번씩 다시 돌렸다. 파일럿 20게임(탐욕 정책이 성공한 10개와 실패한 10개, 샘플 seed 0)과 새 본 규모 80게임(나머지 탐욕 게임에서 seed 1로 무작위 추출한 성공 40개와 실패 40개, 샘플 seed 1)이다. 탐욕 결과에 따른 층화는 파일럿 뒤에 정했으며, 선택 단계로 보고한다. 모두 800개 rollout을 사용했다. 이 100게임은 탐욕 게임 500개에서 뽑았으므로 앞 250개와 겹칠 수 있고, 시도 수준에서 프로브와 baseline은 샘플링 rollout만으로 장면 단위 교차적합했다. 새로 설치한 환경에서 본 규모의 처음 24개 rollout을 다시 수집했을 때 action, 결과, hidden state가 모두 같았다.

추가 탐욕 데이터(학습 표본 수 sweep). 4.8절의 학습 표본 수 sweep을 위해, 앞 500개에 들지 않은 학습 게임 3,053개에서 seed 0으로 비복원 추출한 새 게임 1,000개(층화 없음)에서 같은 actor, 프롬프트, 디코딩으로 탐욕 episode 1,000개를 더 수집했다. sweep은 이를 앞 500개와 합쳐 쓴다(1,500개 episode, step 0–2).

3.4 평가 단위

과제 수준(게임 간). 라운드 r마다 step r에 아직 진행 중인 episode당 한 행을 두고 실패 예측 AUROC를 계산했다. 한 라운드 안에서는 step 번호가 같으므로 episode 길이가 예측 변수가 될 수 없다. 사전 등록한 라운드 1–3은 step 0–2(처음 세 action)이며, 이 step에서는 모든 episode가 진행 중이었다.

시도 수준(게임 내). 같은 게임의 rollout은 step 0 프롬프트가 모두 같으므로 step 0을 빼고 step 1–3을 평가했다. 8개 rollout 중 성공과 실패가 모두 있는 게임만 평가에 들어간다. 지표는 게임 내 쌍 AUROC이다. 같은 게임의 (실패, 성공) rollout 쌍 전체에서 실패 rollout의 실패 점수가 더 높은 비율(동점은 1/2)을 구하고, 게임별 쌍 수에 비례하는 가중치로 합쳤다.

시도 수준 결과를 읽기 전에 이 설계의 두 가지 성질을 점검했다. 첫째, 같은 게임의 샘플링 rollout은 아직 갈라지지 않은 경우가 많았다. step마다 평가 쌍은 470개(성공과 실패가 모두 나온 게임 39개, 장면 28개)였고, 그중 프롬프트가 같은 쌍이 step 1, 2, 3에서 70.4%, 66.4%, 52.3%였다. 이런 쌍은 프로브 입력이 같아 동점이 되므로, 프로브의 쌍 AUROC 상한은 0.648, 0.668, 0.739

가 된다. 둘째, 3–5단은 반복 횟수와 현재 step에서 샘플링된 action의 확률을 포함한다. 이 값은 프로브 입력보다 시간상 뒤에 있고, 바로 rollout이 갈라지는 지점이다. 그래서 보조 분석 두 개를 미리 정했다. (i) 프롬프트가 다른 쌍만으로 같은 지표를 계산하는 것과, (ii) 이 두 특징을 직전 step 값으로 바꾼 시점 맞춘 4t·5t단이다. 보조 결과는 주 결과 다음에 보고하며 주 결과를 대체하지 않는다.

3.5 예측 방법

프로브. 표준화 후 클래스 가중치를 균형 맞춘 L2 정규화 로지스틱 회귀이다. 정규화 강도 $C \in \{10^{-4}, 10^{-3}, 10^{-2}, 10^{-1}, 1\}$은 각 학습 fold 안의 3-fold 교차검증(nested)으로 골랐다. 은닉층 하나(64개 유닛, $\alpha = 10^{-2}$, early stopping, 하이퍼파라미터 고정)의 MLP는 탐색적 프로브로만 평가했다.

baseline 사다리. 각 단은 hidden state 없이 얻을 수 있는 정보를 하나씩 더한다. (1) step 번호, (2) + 과제 유형, (3) + 최근 반복 횟수, 고른 action의 확률, 후보 수, (4) + 이전 action에서 계산한 진행도(방문한 서로 다른 장소 수, open/take/변환/move 횟수, 목표 물체를 본 적이 있는지), (5) + user 메시지 전체의 TF-IDF(단어 1–2-gram). user 메시지에는 과제 문장, 방 묘사, 최근 기록, 현재 관찰, 가능한 action 목록이 들어 있다. 3단은 현재 step의 점수화 이후 값을 쓰므로 프로브 입력보다 조금 늦은 정보이며, baseline에 유리한 쪽이다. 프로브는 5단과 비교했고(사전 등록), 시도 수준에서는 4단과 5단 모두와 비교했다.

난이도 오라클(시도 수준 분석). 과제 수준 데이터에서 얻은 각 게임의 탐욕 결과로, 샘플링 rollout과 독립이다. 게임 안에서는 상수이므로 게임 내 AUROC가 정의상 0.5이다(구현 점검으로 확인). 결과 분산 중 게임이 설명하는 비율(η^2)과, 게임을 합친 행에서 [오라클, 예측 방법]을 결합한 로지스틱의 AUROC가 오라클 단독보다 얼마나 높은지도 보고한다.

3.6 교차적합, 통계, 사전 등록

모든 예측 방법은 **장면**(ALFWorld의 방 배치, 앞 250개 게임에서 86개) 단위로 묶은 5-fold 층화 그룹 분할로 교차적합했다. seed 2개로 반복해 평균했으므로, 모든 행은 그 장면을 보지 못한 모델이 점수를 매겼다. 게임 단위로 나누면, 장면 정보만 담은 합성 특징에서도 AUROC가 0.97까지 부풀었다. 표준화, TF-IDF, 모델 선택은 모두 각 학습 fold 안에서 학습했다.

과제 수준의 95% 신뢰구간은 장면 단위 cluster bootstrap(1,000회)으로 구했고, 프로브와 baseline의 차이는 같은 재표집에서 짝지어 계산했다. 귀무분포는 라벨을 섞은 뒤 nested 선택을 포함한 전체 절차를 다시 돌려 얻었다(순열 100회). 시도 수준의 신뢰구간은 게임 단위 bootstrap(1,000회)이고, 귀무분포는 점수를 고정한 채 게임 안에서 라벨을 섞어 얻었다(순열 1,000회).

프로브를 학습하기 전에 코드 commit, 설정, 주 분석(3B actor와 reader, 50% 깊이, 선형 프로브, 라운드 1–3, 5단과의 비교)을 고정하고 한 번만 실행했다. 50% 깊이는 근거를 기록하지 않은 채 계획에 고정했고, H1이 세 라운드 모두를 요구하는지 하나만 요구하는지는 계획에 없었다. 세 차이가 모두 0 아래였으므로 판정은 그 규칙에 달려 있지 않다. 같은 episode에서 그 뒤에 한 분석은 모두 탐색적이라고 표시한다. 그중 한 설정(75% 깊이, 선형)을 확증용 홀드아웃에서 검증했으며, 500개 episode 전체로 학습하고 250–499번 episode만 평가했다. 판정 규칙은 차이의 95% 하한이 0보다 크면 우수, −0.05보다 크면 비열등, 상한이 0보다 작으면 열등, 그 밖에는 결론 없음이다. 마진 0.05는 탐색 분석 뒤에 정했다. 시도 수준 분석(75% 깊이, 선형, 4·5단과 비교, step 1–3)과 결과별 해석표(부록 표 A7)는 샘플링 rollout을 수집하기 전에 정했다. 고정한 절차를 바꾼 경우는 모두 날짜와 함께 저장소에 기록했다. 100 action 재수집의 판정 전에 중간 집계를 두 번 보았다(처음 116개 게임에서 늦은 성공 최대 3개). 판정 규칙은 그 전에 commit했고 바꾸지 않았다. 등록한 계획에서 벗어난 점과 판정 전 결과 노출은 모두 부록 표 A8에 적었다.

3.7 계산 환경

NVIDIA RTX 4070(12 GB) 1장, WSL2(Ubuntu 22.04), Python 3.11, PyTorch 2.11(CUDA 12.8), Transformers 5.19.0을 사용했다. episode 하나를 수집하는 데 약 8–11초가 걸렸고, 본 규모 640개 rollout은 88분이 걸렸다.

모니터 비용. [2]를 따라 파라미터 N개 모델의 추론 계산량을 토큰당 $2N$ 부동소수점 연산으로 근사했다. 그러면 같은 토큰을 읽는 별도 모니터의 추가 비용은 actor 대비 파라미터 수의 비율이다. 이는 모니터가 actor가 읽는 토큰을 모두 읽는다고 가정한 것이다. [2]는 토큰당 비율보다 낮은 전체 비용(0.1–0.6%)을 보고하므로, 그 값은 모니터가 읽는 토큰 수에도 달려 있다. Qwen2.5의 공개 파라미터 수(0.5B: 전체 0.49B, 임베딩 제외 0.36B; 3B: 3.09B와 2.77B; 7B: 7.61B와 6.53B)로 계산하면, 0.5B 모니터는 3B actor에 $0.36/2.77 \approx 13\%$에서 $0.49/3.09 \approx 16\%$를 더하고, 7B 모니터는 actor의 $6.53/2.77 \approx 2.36$배에서 $7.61/3.09 \approx 2.46$배(약 2.4배)가 든다. actor 자신의 hidden state를 읽는 프로브는 step마다 2,048차원 벡터와의 내적 하나를 더할 뿐이며 모델을 다시 부르지 않는다. 에너지와 지연은 측정하지 않았다.

4 결과

4.1 과제 수준

데이터. 탐욕 actor는 앞 250개 episode 중 56개(22.4%, Wilson 95% CI 17.7–28.0%), 500개 전체 중 101개를 성공했다. 250개 게임은 86개 장면에 걸쳐 있었다. 성공 episode는 4–28 action(중앙값 12)이 걸렸으므로 step 0–3에서는 250개 episode가 모두 진행 중이었고, 사전 등록한 모든 라운드에서 실패 비율은 0.776이었다.

baseline. hidden state 없이 보이는 정보만으로도 첫 action 전에 실패가 예측되었다(표 1, 그림 1). 과제 유형만으로 AUROC가 0.603이었고, 5단 baseline은 step 0에서 0.701, step 1에서 0.732, step 2에서 0.823이었다. step 2 이후의 상승은 대부분 진행도 특징(4단)에서 나왔다($0.673 \rightarrow 0.834$). step 2와 3에서는 5단이 4단보다 높지 않았다. step 번호만 쓰는 1단은 의도대로 모든 라운드에서 정확히 0.500이었다. 라벨을 섞은 순열의 AUROC는 평균 0.50(95% 범위 약 0.38–0.62)이었다.

사전 등록 비교. 한 번 실행한 사전 등록 분석(3B reader, 50% 깊이, 선형 프로브)에서 프로브는 세 라운드 모두 5단 baseline보다 낮았고, 차이의 95% 신뢰구간은 모두 0 아래였다(표 1, 그림 2). step 0에서 -0.181(-0.276 ~ -0.069), step 1에서 -0.133(-0.230 ~ -0.031), step 2에서 -0.159(-0.240 ~ -0.073)였다. 따라서 사전 등록한 조건에서 가설 H1은 지지되지 않았다. 이는 미리 고정한 해석표(부록 표 A7)의 세 번째 경우("3B reader도 5단을 이기지 못함")에 해당한다.

탐색 분석(같은 250개 episode). 이어서 reader 4종, 깊이 4종, 프로브 2종, 라운드 3개의 96개 조합을 모두 평가했다(선형 프로브 칸은 그림 3, 전체는 부록 표 A9). baseline보다 0.004 넘게 높은 조합은 없었고, 차이가 양수인 두 조합(+0.004, +0.001)도 신뢰구간이 0을 포함했다. 75% 깊이는 모든 reader에서 가장 좋거나 그에 가까웠다. 3B reader의 75% 깊이 선형 프로브는 baseline 대비 -0.034 ~ -0.011이었다(신뢰구간은 모두 0을 포함). step 0–2 평균으로 보면 가장 좋은 깊이의 선형 AUROC는 0.660(0.5B), 0.717(1.5B), 0.727(3B), 0.717(7B 4비트, 최고 깊이 100%)로, reader 크기에 따른 단조 증가는 없었다. 7B 결과는 양자화와 교락되어 있다. 깊이를 평균하면 고정 설정의 MLP는 선형 프로브보다 낫지 않았다(차이 -0.035 ~ -0.004). reader 쌍 비교 36개 중 신뢰구간이 0을 벗어난 것은 4개로, 우연히 기대되는 약 2개와 비슷했고 부호도 일관되지 않았다. 이 분석들은 사전 등록 결과를 본 뒤에 정한 것이므로 그 자체로는 근거가 아니다.

표 1: Failure-prediction AUROC on the first 250 episodes (pre-registered rounds: steps 0–2).

	Step 0	Step 1	Step 2	Step 3[a]
Rung 1: step index	0.500	0.500	0.500	0.500
Rung 2: + task type	0.603	0.603	0.603	0.603
Rung 3: + repetition, chosen-action probability	0.659	0.633	0.671	0.700
Rung 4: + progress	0.673	0.700	0.834	0.814
Rung 5: + TF-IDF of prompt	0.701	0.732	0.823	0.818
Probe, 3B reader, 50% depth (pre-registered)	0.520	0.599	0.665	–
Probe − rung 5 (95% CI)	−0.181 (−0.276, −0.069)	−0.133 (−0.230, −0.031)	−0.159 (−0.240, −0.073)	–

$n = 250$ episodes (194 failures) per round; CIs from a scene-level cluster bootstrap (1,000 resamples). [a]baseline 만. step 3은 사전 등록 라운드가 아니며 프로브는 평가하지 않았다.

표 2: Confirmatory hold-out (episodes 250–499; 3B reader, 75% depth, linear).

	Step 0	Step 1	Step 2
Probe AUROC (95% CI)	0.645 (0.547, 0.736)	0.716 (0.619, 0.810)	0.729 (0.633, 0.815)
Rung 5 AUROC	0.607	0.681	0.758
Probe − rung 5 (95% CI)	+0.039 (−0.030, +0.100)	+0.035 (−0.030, +0.096)	−0.029 (−0.087, +0.029)
Decision (margin 0.05, set post hoc)	non-inferior	non-inferior	inconclusive

$n = 250$ episodes (205 failures). Training used all 500 episodes; evaluation used only the new 250. 마진 민감도 (같은 신뢰구간으로 읽음; 하한 −0.030, −0.030, −0.087, 상한은 모두 0 위): 마진 0.025이면 비열등인 step이 없고, 0.10이면 세 step 모두 비열등이다. 마진을 사후에 정했으므로 근거는 판정 라벨이 아니라 차이와 신뢰구간이다.

확증 홀드아웃. 탐색에서 고른 한 설정(3B reader, 75% 깊이, 선형)을 새 250개 episode에서 평가했다(실패 205개, 실패 비율 0.82, 표 2). 5단과의 차이는 step 0–2에서 +0.039(−0.030 ~ +0.100), +0.035(−0.030 ~ +0.096), −0.029(−0.087 ~ +0.029)였다. 우수 기준을 충족한 라운드는 없었고 열등한 라운드도 없었다. step 0과 1은 비열등 규칙(마진은 탐색 뒤에 정함)을 충족했고 step 2는 결론이 나지 않았다. 5단 baseline은 홀드아웃에서 앞 250개보다 낮아(step 0에서 0.607 대 0.701), 표본에 따라 이 정도의 변동이 있음을 보여 준다.

4.2 시도 수준

주 결과. 게임 안에서 프로브의 쌍 AUROC는 step 1에서 0.520(95% CI 0.453–0.583), step 2에서 0.585(0.522–0.654), step 3에서 0.619(0.552–0.687)였다(표 3, 그림 2). 4단과 5단은 각각 0.517과 0.547, 0.611과 0.626, 0.565와 0.612였다. step 2부터는 세 방법 모두 같은 게임의 실패 시도와 성공 시도를 우연보다 잘 구분했고(게임 안 순열 $p \leq 0.018$), step 1에서는 5단만 그랬다($p = 0.016$). 이 판정은 순열 검정에 따른 것이며, step 3에서 4단의 95% bootstrap 구간(0.492–0.644)은 0.5를 포함한다. 프로브–baseline 차이 6개 중 우수 기준을 충족한 것은 없었고 열등한 것도 없었다. 가장 큰 차이는 step 3의 4단 대비 +0.054(−0.017 ~ +0.136)였다. 결과는 해석표(부록 표 A7)의 어느 줄에도 깔끔하게 들어가지 않는다. 프로브는 baseline보다 낫지 않았고, 동등 정의(95% CI가 ±0.05 안)를 충족한 비교도 없었다. 이 표본 크기에서 차이 6개의 95% 신뢰구간 폭은 0.088–0.154였다. 동등 기준을 충족하려면 구간 폭이 0.10보다 좁고 구간 전체가 0에서 ±0.05 안에 있어야 하는데, 폭 조건은 셋이 충족했지만 위치까지 충족한 구간은 없었다. 따라서 "동등" 판정이 없는 것은 데이터만큼 표본 크기(6절) 때문이기도 하다.

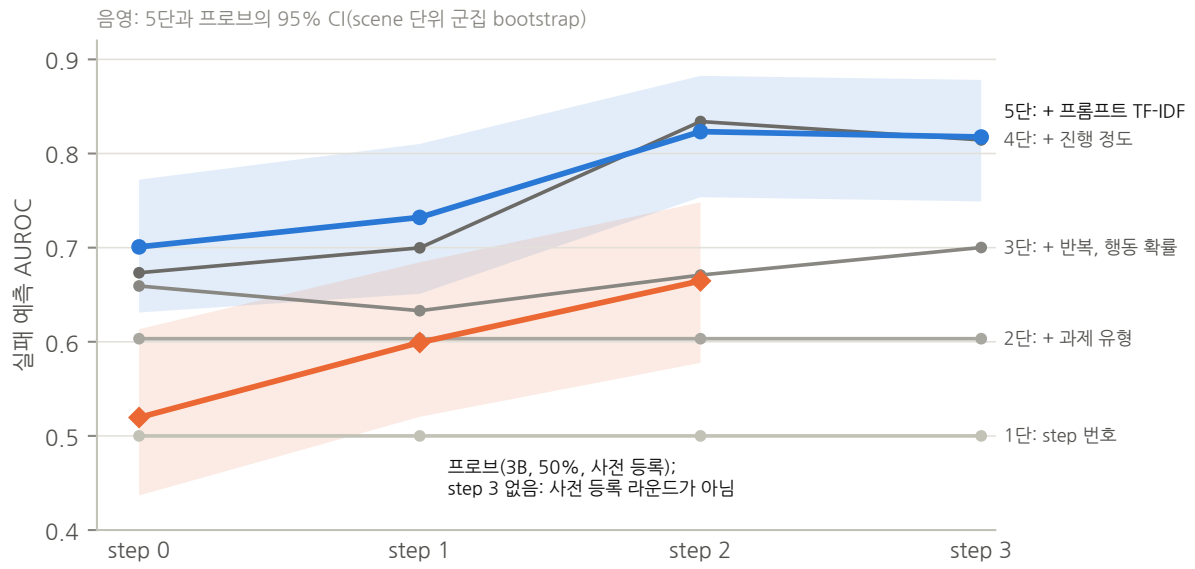


그림 1: 처음 250 episode에서 baseline 사다리(step 0–3)와 사전 등록 프로브(step 0–2)의 실패 예측 AUROC(step마다 $n = 250$, 실패 194). 5단과 프로브를 강조하고 scene 단위 군집 bootstrap(1,000회) 95% CI를 음영으로 표시했다. 1–4단의 CI는 가독성을 위해 생략했다. 1단은 설계상 0.5이고 2단은 step에 따라 변하지 않는다. 두 음영이 겹치는지는 차이의 검정이 아니며, 짝지은 차이는 그림 2에 있다.

표 3: Within-game pairwise AUROC ($T = 1$ sampling; 39 games with both outcomes, 470 pairs per step).

	Step 1	Step 2	Step 3
Probe (3B, 75% depth, linear)	0.520 (0.453, 0.583)	0.585 (0.522, 0.654)	0.619 (0.552, 0.687)
Rung 4	0.517 (0.452, 0.582)	0.611 (0.541, 0.687)	0.565 (0.492, 0.644)
Rung 5	0.547 (0.478, 0.618)	0.626 (0.563, 0.699)	0.612 (0.546, 0.682)
Probe − rung 4 (95% CI)	+0.003 (−0.058, +0.063)	−0.026 (−0.078, +0.019)	+0.054 (−0.017, +0.136)
Probe − rung 5 (95% CI)	−0.027 (−0.088, +0.025)	−0.040 (−0.088, +0.002)	+0.007 (−0.038, +0.051)
Tied pairs (identical prompts)	70.4%	66.4%	52.3%

CIs from a game-level bootstrap (1,000 resamples). Rung 2 and the difficulty oracle are constant within a game and scored exactly 0.500 (implementation check).

보조 분석. 프롬프트가 다른 쌍만으로 평가하면(step 1–3에서 139, 158, 224쌍) 모든 방법이 높아졌지만(프로브 0.568, 0.753, 0.750; 5단 0.633, 0.816, 0.754), 차이 6개는 모두 결론이 나지 않았다(구간 약 ±0.1–0.2). 시점을 맞춘 4t·5t단과 비교하면 프로브는 어느 step에서도 낫지 않았고, step 1에서는 둘보다 낮았다 (−0.045, −0.098 ~ −0.006; −0.038, −0.084 ~ −0.004). 다만 Holm 보정 뒤에는 유의하지 않았다($p = 0.18$). 따라서 동점 쌍도 시점 비대칭도 프로브 우위가 없는 이유를 설명하지 못한다. 동점 쌍 889개 모두에서 프로브와 시점 맞춘 baseline의 점수가 같아, 세 방법이 같은 시점의 정보를 쓴다는 것을 확인했다.

구간의 보정. 라벨을 섞은 데이터(seed 20개)에서 게임 단위 percentile bootstrap 구간이 귀무값을 포함한 비율은 95%가 아니라 80–94%였고, "동등" 판정이 귀무 실행의 54–65%에서 나왔다. 위의 경계 판정은 이 점을 감안해 읽어야 한다.

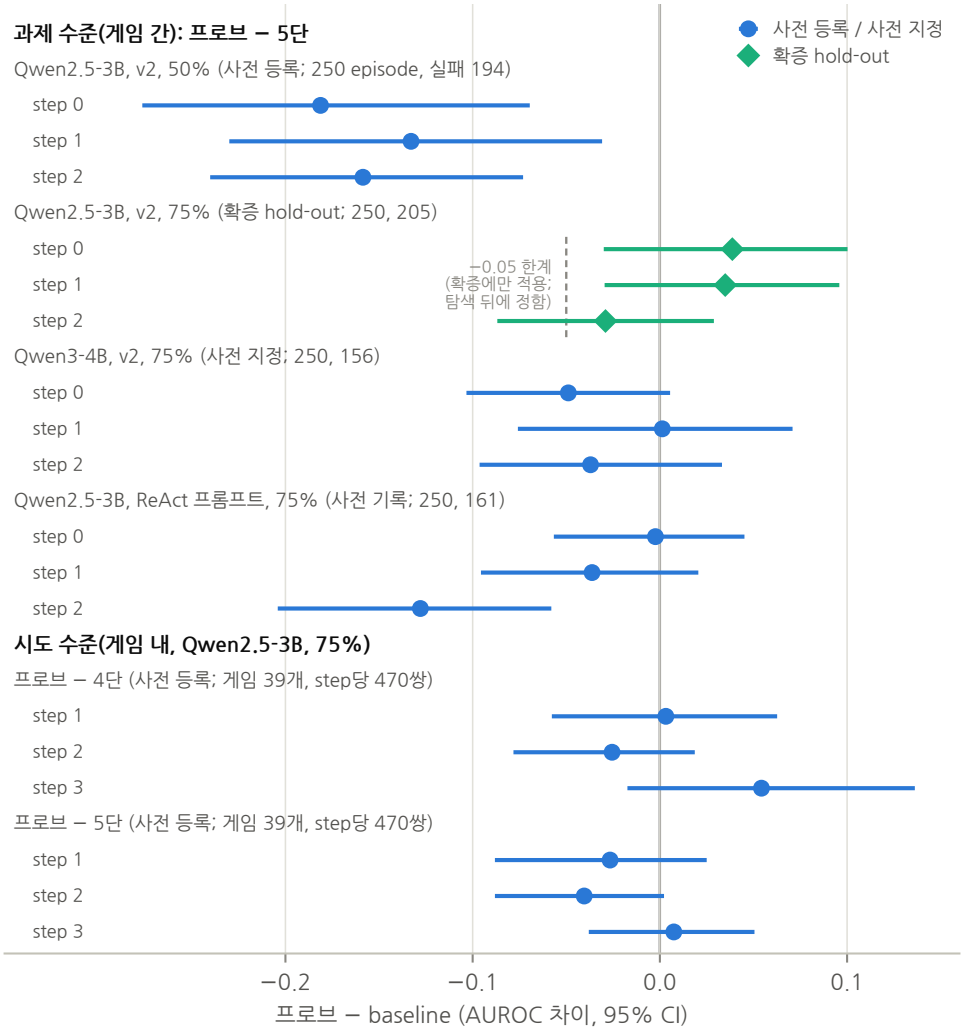


그림 2: 사전 등록·사전 지정·확증 프로브 대 baseline 비교 전부(18개, 우수 0개). 이 비교들은 게임과 baseline을 공유해 독립이 아니므로, 개수는 합친 추정치가 아니다. 점은 AUROC 차이, 막대는 95% CI. 과제 수준: 프로브 − 5단, scene 단위 군집 bootstrap(1,000회), 라벨에 설정과 n(episode, 실패). 시도 수준: 게임 내 쌍 AUROC 차이, 게임 단위 bootstrap(1,000회). 라벨을 섞은 데이터에서 이 구간은 귀무값을 80–94%만 포함해(4.2절) 실제보다 좁다. 점선: 비열등 한계 −0.05, 확증 hold-out에만 적용하며 탐색 분석 뒤에 정했다. 탐색 추정치는 넣지 않았다(그림 3).

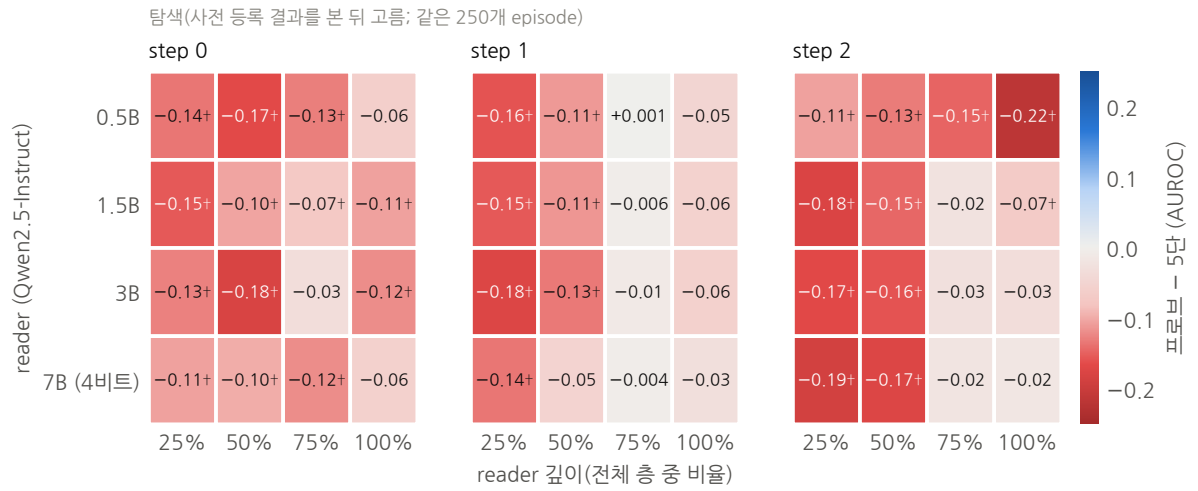


그림 3: 탐색: 처음 250 episode에서 선형 프로브의 모든 reader × 깊이 조합의 프로브 – 5단 AUROC 차이(48칸, 선택 없음). 0을 중심으로 한 발산 색(빨강: 프로브가 5단보다 낮음). †는 95% CI(scene 단위 군집 bootstrap)가 0을 포함하지 않는 칸이며 모두 0 아래다(48칸 중 31칸). CI가 0 위에 있는 칸은 없고 가장 큰 차이는 +0.001이다. 7B reader는 4비트 가중치를 써서 크기와 양자화가 섞여 있다. 선형·MLP 칸과 CI: 부록 표 A9.

4.3 결과가 게임에 의해 정해지는 정도

샘플링 데이터에서 결과 분산 중 게임이 설명하는 비율은 $\eta^2 = 0.695$(95% CI 0.613–0.765)였다. 게임을 탐욕 결과로 층화해 골랐으므로 모집단 값은 아니다. 게임을 합친 행에서 난이도 오라클 단독 AUROC는 0.877이었다. 오라클에 프로브를 더하면 합친 AUROC가 step 1–3에서 −0.002(−0.026 ~ +0.025), +0.022(−0.005 ~ +0.048), +0.042(+0.017 ~ +0.073) 바뀌었고, 5단을 더하면 +0.004(−0.018 ~ +0.027), +0.034(+0.007 ~ +0.060), +0.029(+0.003 ~ +0.058) 바뀌었다. 이 증가분은 보정하지 않은 보조 지표이다. 즉 어느 방법이든 게임 간에 예측하는 것의 대부분은 게임을 아는 것만으로 이미 예측된다.

4.4 다른 actor와 두 번째 프롬프트

모델과 프롬프트마다 따로 보고하며 결과를 합치지 않는다.

어떤 actor가 들어갔나. 다섯 모델을 처음 20게임에서 파일럿했고, 포함 규칙은 파일럿 전에 정했다(20개 중 성공 3개 이상, 12 GB 메모리 안에서 완료, episode당 시간이 기준의 3배 이내, hidden state에 NaN·inf 없음; 부록 표 A1). 통과한 모델은 Qwen3-4B(thinking 끔, 7/20 성공)뿐이었다. Qwen3-1.7B, Llama-3.2-3B-Instruct, SmolLM3-3B, Phi-3.5-mini-instruct는 각각 20개 중 1개만 성공해 (Wilson 95% CI 1–24%) 제외했고, Phi-3.5-mini는 시간 기준도 넘었다. SmolLM3 파일럿 전에, 결과를 본 뒤 대체 모델을 고르지 않도록 기준을 통과한 모델은 모두 넣는 것으로 규칙을 바꾸었다. 미리 정한 대체 후보를 다 쓴 뒤에는 모델을 더 추가하지 않았으므로, 모델 확장은 Qwen 모델 2개에 한정된다. 제외된 모델은 최근 6 step 안에서 같은 action을 반복한 비율이 Qwen 두 모델보다 훨씬 높았다(66–82% 대 32–51%; 탐색적 기술, 부록 표 A2). v2는 Qwen2.5로 조정한 프롬프트이므로 모델 능력보다 프롬프트와 모델의 궁합 때문일 수 있다. 모델당 20게임이라 성공률 차이는 주장하지 않는다.

Qwen3-4B, 과제 수준. 같은 250게임에서 탐욕 Qwen3-4B actor는 94개를 성공했다(37.6%; Qwen2.5-3B는 56개). 깊이(75%)와 5단과의 비교는 이 데이터를 모으기 전에 정했다. actor 자신의 hidden state로 학습한 프로브는 어느 라운드에서도 5단을 넘지 못했다 (표 4): step 0에서 −0.049(−0.103 ~ +0.005), step 1에서 +0.001(−0.076 ~ +0.071), step 2에서 −0.037(−0.096 ~

+0.033). 우수한 라운드는 없었고(세 라운드 Holm 보정 후에도), 비열등이나 열등도 없어 세 라운드 모두 결론 없음이었다. 방향은 Qwen2.5-3B와 같다. actor 자신의 hidden state를 읽는 프로브가 겉보기 baseline보다 낮다는 결과는 나오지 않았다.

Qwen3-4B, 시도 수준. Qwen3-4B의 샘플링 rollout은 거의 갈라지지 않았다. 8회 중 성공과 실패가 모두 나온 게임은 50개 중 10개뿐이었고(Qwen2.5-3B는 100개 중 39개), step 1–3에서 고른 action의 확률이 0.99를 넘은 경우가 77%였다. 모든 방법의 게임 내 AUROC는 0.47–0.52였고 쌍대부분이 동점이었다. 결과를 읽기 전에 표본을 늘리지 않고 부록에만 싣기로 정했다(표 A3). 이 모델로는 시도 수준 질문에 답할 수 없었다.

두 번째 프롬프트(ReAct 예시). 결론이 직접 만든 프롬프트에 달려 있는지 보려고, 같은 250 게임에서 Qwen2.5-3B를 ReAct [13]의 원 ALFWorld 예시로 다시 돌렸다. 바꾼 것은 action 문법을 `alfworld` 0.4.2에 맞춘 것뿐이다(`put A in/on B` → `move A to B`). 두 프롬프트는 여러 점이 동시에 다르다(부록 표 A4). ReAct 프롬프트는 chat template이 아닌 completion 문자열이고, 고정 예시 하나 대신 현재 과제 유형에 맞춘 예시 두 개를 쓰며, 최근 6 step 대신 전체 기록을 유지하고, 가능한 action 목록과 실패 action 안내가 없다. 정책, 게임, 분석, 판정 규칙은 그대로 두었고, 5단의 텍스트는 예시를 뺀 현재 게임 부분만 썼다. 따라서 이 프롬프트는 결론을 점검하는 용도이며, 특정 프롬프트 요소의 효과를 추정한 것이 아니다.

사전 기록한 비교(75% 깊이, linear, 5단 대비; 성공 89개)는 step 0에서 -0.002(-0.057 ~ $+0.045$), step 1에서 -0.036(-0.096 ~ $+0.021$), step 2에서 -0.128(-0.204 ~ -0.058)이었다(표 4). 우수한 라운드는 없었고(Holm 보정 후에도), step 0과 1은 결론 없음, step 2는 열등이었다. 미리 정한 해석대로, 외부 프롬프트에서도 프로브가 겉보기 baseline보다 낮다는 증거는 없었다. 두 프롬프트 사이의 격차 크기는 검정하지 않았고 실패 비율도 달라서(0.776 대 0.644) 비교하지 않는다. 50% 깊이(보조)에서는 -0.036, -0.032, -0.048로 모두 결론 없음이었다. 이 설정에서 ReAct 형식 프롬프트는 v2보다 자주 성공했다 (250개 중 89개 대 56개; 짝지은 차이 +0.132, 95% CI 0.060–0.204; 정확 McNemar $p = 0.0006$). 여러 요소가 함께 바뀌었으므로 어느 하나의 효과로 돌리지 않는다.

탐색적 점검으로, v2 궤적으로 학습한 프로브를 ReAct 궤적에 적용하면(시험 게임의 장면은 학습에서 제외) step 0–2에서 0.527, 0.493, 0.555였다. 이는 ReAct 안에서 학습한 프로브(0.659, 0.623, 0.593)보다 낮았다(step 0과 1의 차이는 신뢰구간이 0 아래). 라벨 없이 ReAct 상태를 다시 표준화해도 나아지지 않았다(0.550, 0.482, 0.586). 프로브가 배우는 방향이 프롬프트 형식에 묶여 있음을 시사한다. 다만 두 프롬프트는 hidden state를 뽑는 토큰도 달라서, 신호가 다른 것인지 표현 위치가 옮겨 간 것인지는 가를 수 없다.

설정 전체 요약. 과제 수준 평가 네 가지(사전 등록, 확증, Qwen3-4B, ReAct 프롬프트)의 12개 라운드 중 프로브가 5단보다 우수한 라운드는 0개였다(그림 2).

4.5 기존 실패 예측·불확실성 방법과의 비교

우리 결과를 기존 에이전트 모니터와 연결하려고, 선행연구의 과제를 보지 못하는 baseline 두 개를 매 step 저장한 값으로 근사했다(탐색; 계획은 실행 전 고정). 행동 baseline은 [7]의 scorer를 따랐다. 현재와 직전 step에서 고른 action의 로그확률, 토큰 평균 로그확률, 토큰 수, 프롬프트 길이, 현재 관찰의 오류 문구 수(후보 점수화에서는 항상 0)이다. 로그확률 baseline은 [1]을 따랐다. 후보 분포의 엔트로피, 1·2위 후보의 점수 차, 고른 action의 확률, 후보 수, 현재와 직전 step에서 고른 action의 토큰 평균 로그확률이다. action을 생성하지 않고 점수화하므로 이 특징들은 원래 특징의 근사이며 재현이 아니다. 분할, 통계, 프로브(75% 깊이, linear)는 4.1절과 같고 앞 250개 episode를 썼다.

이 과제를 보지 못하는 baseline들과 비교하면 프로브가 분명히 나았다(표 5). step 0–2에서 행동 baseline보다 +0.145(0.032 ~ 0.247), +0.167(0.070 ~ 0.247), +0.190(0.107 ~ 0.282), 로그확률 baseline보다 +0.040(-0.060 ~ +0.133), +0.176(0.051 ~ 0.297), +0.189(0.074 ~ 0.296) 높았다.

표 4: Task-level probe − rung 5 (AUROC difference, 95% CI) across settings.

Setting	Step 0	Step 1	Step 2
Qwen2.5-3B, v2, 50% depth (pre-registered; $n = 250$, 194 failures)	−0.181 (−0.276, −0.069)	−0.133 (−0.230, −0.031)	−0.159 (−0.240, −0.073)
Qwen2.5-3B, v2, 75% depth (confirmatory hold-out; 250, 205)	+0.039 (−0.030, +0.100)	+0.035 (−0.030, +0.096)	−0.029 (−0.087, +0.029)
Qwen3-4B, v2, 75% depth (pre-specified; 250, 156)	−0.049 (−0.103, +0.005)	+0.001 (−0.076, +0.071)	−0.037 (−0.096, +0.033)
Qwen2.5-3B, ReAct prompt, 75% depth (pre-recorded; 250, 161)	−0.002 (−0.057, +0.045)	−0.036 (−0.096, +0.021)	−0.128 (−0.204, −0.058)

프로브와 5단 AUROC: Qwen3-4B 0.660/0.687/0.680 대 0.709/0.686/0.717, ReAct 프롬프트 0.659/0.623/0.593 대 0.661/0.660/0.721. 장면 단위 cluster bootstrap 1,000회.

표 5: Exploratory: task-level AUROC of prior-style baselines, first 250 episodes.

	Step 0	Step 1	Step 2
Behavioral features (after [7])	0.522	0.554	0.605
Log-probability features (after [1])	0.626	0.545	0.606
Behavioral + task type	0.626	0.656	0.689
Rung 5	0.701	0.732	0.823
Probe (75% depth, linear)	0.666	0.721	0.795
Probe − behavioral (95% CI)	+0.145 (0.032, 0.247)	+0.167 (0.070, 0.247)	+0.190 (0.107, 0.282)
Probe − log-probability (95% CI)	+0.040 (−0.060, 0.133)	+0.176 (0.051, 0.297)	+0.189 (0.074, 0.296)
Probe − rung 5 (95% CI)	−0.034 (−0.102, 0.037)	−0.011 (−0.082, 0.061)	−0.029 (−0.091, 0.027)

step당 $n = 250$(실패 194). 장면 단위 cluster bootstrap 1,000회.

행동 특징에 과제 유형만 더해도 AUROC가 0.08–0.10 올랐고(신뢰구간 모두 0 위), 5단 전체와 비교하면 같은 프로브의 이점이 없었다(−0.034, −0.011, −0.029, 신뢰구간 모두 0 포함). 이 탐색적 비교(15개, 보정 없음)는 선행연구에서 보고된, 과제를 보지 못하는 모니터 대비 hidden state의 이점이 baseline이 과제를 보게 되면 사라질 수 있음을 시사한다. 궤적 텍스트로 미세조정한 텍스트 모니터 [2]는 시험하지 않았다. 그런 모니터가 쓸 수 있는 텍스트 정보는 여기서 5단의 TF-IDF가 담는다.

4.6 조기 중단

실용 동기를 직접 확인하려고, 100 action 시간 한도에서 탐욕 Qwen2.5-3B 500게임에 중단 규칙을 평가했다 (일찍 성공한 101게임은 30 action 궤적, 나머지 399게임은 100 action 재실행; 100 action 안 성공 112개; 40,500 step). 계획은 늦은 성공 결과를 읽기 전에 정했다. 규칙은 각 action 직전에 점수가 문턱 이상이면 episode를 멈추고, 멈춘 episode는 실패로 센다. actor 자신의 hidden state는 어차피 계산되므로 비용은 실행한 action 수로 두었다. 규칙마다 문턱을 훑어, 허용한 성공 손실 ℓ(0–10%, 0.5%p 간격)마다 절감한 step 비율의 최댓값을 구하고 평균했다. 규칙은 step 상한, 루프 감지(직전 action이 그 이전 6 step 안에 나온 횟수; 후보 점수화에서는 "Nothing happens"가 한 번도 나오지 않았다), 시점 맞춘 4t·5t, 프로브(75% 깊이 + step 번호)이고, 학습하는 규칙은 각

표 6: Early termination, Qwen2.5-3B, 500 games, 100-action horizon.

Rule	Mean max. steps saved at ≤10% lost successes (95% CI)	Relative to oracle
Step cap	0.560 (0.468, 0.656)	0.58
Loop detector	0.194 (0.023, 0.361)	0.20
Rung 4t	0.608 (0.477, 0.748)	0.63
Rung 5t	0.625 (0.503, 0.758)	0.65
Probe (75% depth + step)	0.529 (0.382, 0.667)	0.55
Oracle (stop failures at step 0)	0.958 (0.947, 0.969)	1

step에 살아 있는 행으로 장면 단위 교차적합했다. 사전에 정한 주 비교 하나는 프로브와 학습 없는 두 규칙 중 나은 것의 차이이며, 장면 단위 cluster bootstrap(1,000회)으로 평가했다.

이 지표에서 프로브는 step의 0.529(95% CI 0.382–0.667)를 절감했고, step 상한 0.560(0.468–0.656), 루프 감지 0.194(0.023–0.361), 4t 0.608(0.477–0.748), 5t 0.625(0.503–0.758)였다. 실패만 step 0에서 정확히 멈추면 0.958을 절감한다(표 6). 주 비교인 프로브 − step 상한은 −0.032(−0.183 ~ +0.119)로 결론 없음이었다. 이 설정에서 자기 감시의 실용 이득은 확인되지 않았다. 이 판정은 사전에 정한 성공 손실 10% 이하 범위에 대한 것이며, 아래 보조 결과는 손실 범위와 문턱 선택 방식에 따라 달라진다. 보조 분석에서 프로브 − 5t는 −0.096(−0.219 ~ +0.011), 프로브 − 4t는 −0.079(−0.231 ~ +0.067)였다. 손실 전체 범위(0–100%)에서는 프로브가 step 상한보다 나았지만(+0.056, 0.029–0.082) 5t보다 낮았다(−0.023, −0.046 ~ −0.002). 다른 fold에서 손실 5%로 문턱을 고르면 프로브는 step의 0.614를 절감했고(시험 손실 4.5%), step 상한은 0.588(6.3%), 5t는 0.686(5.4%)이었다. 이 보조 결과는 프로브가 고정 상한보다 나은 구간에서도 겉보기 baseline이 적어도 그만큼 낫다는 것을 시사한다. 성공의 10%가 약 11개 episode라 신뢰구간이 넓다. 평가 데이터에서 문턱을 고르면 학습 규칙처럼 고유값이 많은 점수가 약간 유리하다(합성 데이터에서 약 +0.004). 이는 프로브에 유리한 쪽이므로 결론을 바꾸지 않는다.

4.7 강건성 점검

라벨 상한. 100 action 라벨에서 사전 등록 비교는 step 0과 2에서 여전히 열등했고 step 1은 결론 없음이 되었다(상한 +0.005). 확증 비교도 우수한 라운드가 없었다(step 0은 비열등에서 결론 없음으로 바뀜). 원래 라벨로 원래 분석을 현재 소프트웨어 환경에서 다시 돌리면 보고한 값이 모두 그대로 재현되었으므로, 이 변화는 라벨이 바뀐 episode 4개(앞 250개)와 11개(전체 500개)만의 효과이다.

더 강한 프로브. 프로브가 약해서 진 것이 아닌지 확인하려고, 앞 250개 episode에서 기준 프로브와 더 강한 변형 다섯 개를 5단과 비교했다(탐색; 계획은 실행 전 고정, 하이퍼파라미터는 각 학습 fold 안에서 선택). 변형은 넓힌 정규화 격자($C = 10^{-6}$–10^{3}), $k \in \{8, 32, 64, 128\}$의 PCA, 네 깊이를 이어 붙인 8,192차원, 작은 MLP 격자(은닉 32 또는 128, $\alpha = 10^{-3}$ 또는 10^{-1}), 그리고 5단에 75% hidden state를 특징으로 더한 것이다. 18개 비교 중 5단보다 우수한 것은 없었다(표 7). 가장 큰 차이는 +0.013(−0.072 ~ +0.101; 넓힌 격자, step 1)이었고, 이어 붙인 프로브는 step 2에서 5단보다 낮았다(−0.077, −0.159 ~ −0.003; Holm 보정 $p = 0.79$). 5단에 hidden state를 더해도 나아지지 않았다(−0.034, −0.023, −0.024; 신뢰구간 모두 0 포함). fold당 학습 episode가 약 200개라 5단에 2,048차원을 더하면 과적합할 수도 있어, 이 점검은 약하다. 기준 프로브는 앞선 값을 그대로 재현했다. 이 결과는 이 범위 안에서 결론이 프로브의 용량에 달려 있지 않음을 시사한다.

후반 라운드와 시간축 특징. 사전 등록한 처음 세 action 너머로, 아직 진행 중인 episode에서 step 0–10의 75% 선형 프로브를 5단과 비교했다(탐색; step당 224–250개 episode). 차이는 −0.114에서 +0.009 사이였고, 우수한 step은 없었으며, 하나(step 9, −0.114, −0.219 ~ −0.023)는 11개 step에 대한 보정 전 기준으로 열등이었다. step 7부터는 4단의 진행도 특징이 프롬프트에 보이는 최근 6 step보다 오래된 action을 쓰므로, 이 step들에서는 baseline이 프로브 입력에 없는 정보를 본다.

표 7: Exploratory: stronger probes − rung 5 (AUROC difference, 95% CI), first 250 episodes.

Probe	Step 0	Step 1	Step 2
Reference (75% depth, linear, $C \leq 1$)	−0.034 (−0.102, 0.037)	−0.011 (−0.082, 0.061)	−0.029 (−0.091, 0.027)
Wider C grid	−0.036 (−0.105, 0.036)	+0.013 (−0.072, 0.101)	−0.034 (−0.099, 0.026)
PCA (k 8–128)	−0.019 (−0.084, 0.041)	−0.037 (−0.103, 0.032)	−0.029 (−0.091, 0.026)
Four depths concatenated	−0.052 (−0.121, 0.008)	−0.055 (−0.127, 0.023)	−0.077 (−0.159, −0.003)
MLP (grid of 4)	−0.036 (−0.104, 0.023)	−0.025 (−0.105, 0.058)	−0.052 (−0.122, 0.017)
Rung 5 + hidden state	−0.034 (−0.101, 0.037)	−0.023 (−0.096, 0.047)	−0.024 (−0.086, 0.032)

5단 AUROC 0.701, 0.732, 0.823. step당 $n = 250$(실패 194). 장면 단위 cluster bootstrap 1,000회.

이전 step들의 hidden state 누적 평균을 단독으로 또는 현재 상태와 함께 쓴 프로브도 step 1, 2, 3, 5에서 5단보다 낫지 않았다(차이 −0.046 ~ +0.011, 신뢰구간 모두 0 포함).

다른 곳에 이미 보고한 것. 시점 맞춘 baseline과 동점이 아닌 쌍으로 제한한 분석은 4.2절에, 라벨을 섞은 데이터에서의 신뢰구간 보정도 4.2절에, 현재 환경에서 원래 분석을 모두 재현한 결과는 위에 있다. 갈라진 시점에 맞춘 분석, 두 번 넘는 교차검증 seed 분산, 장면 단위 순열 검정, 자유 생성 에이전트와의 비교는 하지 않았다.

4.8 추가 점검

앞 250개 episode의 step 0–2에서 점검 여섯 가지를 더 했다(탐색; 계획은 실행 전 고정, 분석마다 1회 실행; 아래 학습 표본 수 sweep 두 개와 읽는 위치 비교 외에는 홀드아웃 데이터를 쓰지 않음. 이들은 500개 또는 1,500개 전체를 씀). 신뢰구간은 장면 단위 cluster bootstrap(1,000회)이고, 따로 적지 않으면 값은 세 step의 평균이다(표 8, 9). 학습 fold 전체로 학습하면 네 방법(75%·50% 프로브, 4단, 5단) 모두 앞선 값을 그대로 재현했다.

학습 표본 수. 75% 프로브와 5단을 각 바깥 학습 fold의 25, 50, 75, 100%(약 50–200개 episode, 100% 미만은 5번 뽑기)로 학습했다. 프로브 − 5단은 −0.002, −0.011, −0.021, −0.025였고 신뢰구간은 모두 0을 포함했다. 점추정은 줄지 않고 오히려 벌어졌는데, 5단이 데이터에서 얻은 이득(0.684에서 0.752)이 프로브(0.681에서 0.727)보다 컸기 때문이다. 약 400개 episode로 학습한 유일한 결과인 확증 홀드아웃(500개 전체, 5-fold)은 반대 방향(평균 +0.015)이었지만 평가 집합이 달라(step 0의 5단 0.607 대 0.701) 둘을 비교할 수 없다. 50% 프로브는 모든 크기에서 5단보다 낮았다(−0.104 ~ −0.158; 표 9). 같은 평가 행에서 크기를 비교하려고, 500개 episode 전체에서 평가 fold를 고정하고 각 학습 fold의 12.5–100%(약 50–400개 episode)로 sweep을 다시 했다(탐색; 위 결과를 본 뒤 계획했고 홀드아웃을 씀). 프로브 − 5단은 +0.016, +0.005, +0.011, +0.009, +0.006으로 신뢰구간이 모두 0을 포함했다. 약 50개에서 약 400개로 갈 때의 변화는 −0.010이고 95% 신뢰구간이 −0.038 ~ +0.022라, 변화는 탐지되지 않았지만 약 0.02까지의 좁아짐은 배제하지 못한다. 같은 평가 행(앞 250개)에서 학습을 약 200개(앞 250개)에서 약 400개(500개 전체)로 늘리면 차이가 −0.025에서 −0.003으로, 좁아지는 방향으로 +0.022 움직였다. 두 값 모두 구간 안의 변동이다. 전체 크기로 학습한 결과를 뒤 250개로 제한하면 확증 값이 그대로 재현되었다. 약 400개에서도 두 방법 모두 계속 올라(프로브 0.651에서 0.707, 5단 0.635에서 0.701) 곡선이 평평해지지 않았고, 이것이 아래의 더 큰 sweep의 동기가 되었다. 50% 프로브는 여기서도 모든 크기에서 5단보다 낮았다(−0.042 ~ −0.057).

더 큰 학습 집합(1,500개 episode). 표본을 늘리지 않는다는 규칙의 예외로, 새 게임에서 탐욕 episode 1,000개를 더 수집했다(앞 500개와 겹치는 게임 없음, 같은 actor·프롬프트·디코딩). 크기, 주 대비, 해석 규칙은 수집 전에 썼고 계획과 변경 이력은 저장소에 있다(부록 표 A8). 1,500개 episode 전체(step 0–2, 방 배치 108개)에서 평가 fold를 고정하고 각 바깥 학습 fold의 1/24–전체

(약 50–1,200개 episode)로 sweep을 다시 했다(탐색; 분석은 1회 실행, 저장되지 않은 첫 실행 뒤). 75% 프로브 − 5단은 학습 episode 약 50, 400, 1,200개에서 +0.016, +0.002, −0.006이고 신뢰구간이 모두 0을 포함했다(표 9). 주 대비, 즉 약 1,200개에서의 격차 빼기 약 400개에서의 격차는 −0.008(95% 신뢰구간 −0.017 ~ +0.002)로, 좁아짐은 탐지되지 않았고 점추정은 반대 방향이었다. AUROC 상승의 대부분은 약 400개 이전에 있었다(약 50, 400, 1,200개에서 프로브 0.652, 0.730, 0.742; 5단 0.636, 0.728, 0.747). 차이의 구간 폭(약 0.037)은 학습 크기에 따라 줄지 않았으므로, 폭은 학습 집합이 아니라 평가 행이 정한다. 75% 깊이를 앞 250개에서 고른 선택에서 자유로운 새 1,000개 episode만으로 평가하면 차이는 약 400개에서 −0.000(−0.022, +0.022), 약 1,200개에서 −0.014(−0.037, +0.010)였다. 동등성 마진을 등록하지 않았으므로 두 방법을 동등하다고 부르지 않는다. 기술적으로, 모든 크기에서 차이의 구간은 ±0.05와 ±0.10 안에 있었고 ±0.02 안에 있는 크기는 없었다(`results/sweep1500_margin.csv`). 약 1,200개 학습 episode 너머로 외삽하지 않는다.

4단과의 비교(사후). sweep 결과를 읽은 뒤, 같은 절차로 프로브 − 4단과 5단 − 4단의 구간을 추가했다(다시 계산한 점수가 sweep과 10^{-16} 안에서 일치; 탐색, 비교 횟수 보정 없음). 75% 프로브 − 4단은 학습 episode 약 50, 400, 1,200개에서 +0.024(0.004, 0.044), +0.024(−0.001, 0.049), +0.023(−0.004, 0.049)였고, 5단 − 4단은 +0.008(0.001, 0.014), +0.022(0.009, 0.035), +0.028(0.011, 0.045)였다(표 9). 프로브가 4단을 앞서는 정도는 학습 크기에 따라 변하지 않은 반면(약 400개에서 약 1,200개로의 변화 −0.001, −0.010 ~ +0.008) 5단이 앞서는 정도는 커졌으므로, 프로브 − 5단의 작은 이동은 5단이 추가 데이터에서 더 많이 얻은 데서 온 것으로 보인다. 이런 대비 12개(프로브 − 4단, 5단 − 4단, 프로브 − 5단을 각각 두 학습 크기 사이에서, 1,500개 전체와 새 1,000개만으로 계산) 중 다섯 개는 구간이 0을 벗어났다. 5단 − 4단이 커졌고(1,500개 전체에서 약 50개에서 1,200개로 +0.020, 0.004 ~ 0.035; 새 episode만으로는 +0.012와 +0.025), 프로브 − 5단은 새 episode만으로 −0.014(−0.025 ~ −0.003, 약 400개에서 1,200개)와 −0.036(−0.060 ~ −0.008, 약 50개에서 1,200개) 변했다. 1,500개 전체의 주 대비는 0을 포함했고, 이 구간들은 사후이고 보정하지 않았으며 한 평가 부분집합에 한정되므로 격차가 벌어졌다는 증거로 읽지 않는다. 뒤에 한 순열 점검은 이 1,500개 episode 분석의 장면 단위 구간이 너무 좁다는 쪽을 가리키므로(아래 보정 문단), 여기서 0을 벗어난 구간들은 더 약해진다.

낮은 오탐 구간. 오탐률 10%에서 프로브는 실패의 0.268을, 5단은 0.407을 검출했다(차이 −0.139, −0.273 ~ +0.075). 오탐률 5%의 검출률, 오탐률 10%까지의 부분 AUROC, AUPRC의 차이도 신뢰구간이 모두 0을 포함했고 AUROC와 같은 방향이었다. 성공이 56개라 오탐률 5%는 성공 약 3개에 해당하므로 이 추정은 불안정하다. 조기 중단 규칙의 성공 손실 대 절감률은 그림 4에 그렸다.

게임 단위 분할. fold를 방 배치가 아니라 게임 단위로 나누면 AUROC가 프로브에서 −0.006(−0.037 ~ +0.025), 5단에서 −0.027(−0.057 ~ +0.001) 달라졌다. 장면 정보만 담은 합성 특징에서 본 부풀림은 실제 방법에서 나타나지 않았다. 탐욕 데이터는 게임당 episode가 하나라 이 분할은 episode 단위 분할이기도 하다.

과제 수준 구간 포함률. 라벨을 섞은 데이터(20 seed × 3 step)에서 과제 수준 구간이 귀무값을 포함한 비율은 프로브 90.0%(54/60; Wilson 95% CI 79.9–95.3%), 5단 85.0%(51/60), 둘의 차이 88.3%(53/60)로 95%보다 낮았다. 프로브의 Wilson 구간은 95%와 80%를 모두 포함해 명목 수준과도 시도 수준의 포함률과도 구별되지 않고, 5단은 명목보다 낮다. 60회는 같은 episode를 공유하므로 이 포함률의 구간도 근사이고, 라벨을 섞은 데이터의 포함률은 실제 라벨에서의 포함률을 대신하는 지표일 뿐이다. 대략의 민감도로 사전 등록 비교의 구간 위쪽 절반을 1.26배(포함률 88%, $z \approx 1.555$) 넓혀도 세 상한은 모두 0 아래였고(−0.040, −0.004, −0.051), step 1은 간신히 0 아래였다.

action 토큰 위치. 고른 action의 마지막 토큰에서 hidden state를 읽으면(actor에 teacher forcing, [7]이 읽는 위치) AUROC가 50% 깊이 0.746, 75% 깊이 0.734였다. 75% action 토큰 프로브 − 5단은 −0.019(−0.085 ~ +0.046)였고 우수한 step은 없어, 읽는 위치를 바꿔도 결론은 같았다. 프롬

프트 위치에서 약했던 50% 깊이(0.594)가 action 토큰에서는 75%와 비슷하게 강해, 깊이의 효과가 위치에 달려 있음을 시사한다. action 토큰은 행동을 고른 뒤라 프롬프트 토큰보다 늦은 정보를 담는다.

프롬프트 안의 읽는 위치(사후). 주 프로브가 읽는 프롬프트 마지막 토큰은 `<|im_start|>assistant` 뒤의 줄바꿈으로, 모든 step에서 형태가 같은 템플릿 토큰이다. 1,500개 episode sweep을 읽은 뒤, 저장된 같은 프롬프트를 actor에 teacher forcing으로 다시 넣어 다섯 위치의 hidden state를 더 뽑았다(새 episode 없음, 4,500행; 다시 계산한 마지막 토큰 hidden이 저장값과 완전히 같았고 토큰 수도 모든 행에서 일치). C1은 템플릿의 `assistant` 토큰, C2는 가장 최근 관찰의 마지막 토큰(step 0은 방 설명), C3은 가장 최근 관찰의 평균, C4는 과제 문장부터 후보 action 목록 앞까지의 episode 이력 평균, C5는 프롬프트 전체 평균이다. 위치, 분석(학습 fold 전체, 약 1,200개 episode; 75% 깊이에서 마지막 프롬프트 토큰과의 차이 다섯 개를 한 family로 Holm 보정; 50% 깊이는 기술용) 및 해석 규칙은 실행 전에 고정했고 분석은 1회 실행했다. 1,500개 전체에서 75% 깊이 AUROC는 C1 0.727, C2 0.739, C3 0.731, C4 0.749, C5 0.736으로, 마지막 프롬프트 토큰 0.742, 5단 0.747과 비슷했다. 마지막 프롬프트 토큰과 다른 위치는 없었고(차이 -0.014 ~ $+0.008$, Holm 보정 p 0.33–1.00), 5단을 넘은 위치도 없었다(-0.020 ~ $+0.002$, 구간 모두 0 포함; 표 9). 새 1,000개 episode만으로도 같았다(위치 − 마지막 프롬프트 토큰 -0.010 ~ $+0.013$). 따라서 시험한 위치와 actor 하나, 프롬프트 하나 안에서는 읽는 위치를 바꿔도 결론은 같았고, 약 ± 0.02 이내의 차이는 구분하지 못한다. 50% 깊이에서는 위치에 따라 0.662(C1)부터 0.743(C4)까지 더 퍼졌고, 같은 깊이의 마지막 프롬프트 토큰은 sweep에서 0.678이었다. 사전 등록한 50% 칸이 약했던 것이 읽는 위치에 달려 있다는 해석과 맞고 action 토큰 점검도 그렇게 시사했지만, 시험하지는 않았다. 구간이 0을 벗어난 비교는 이력 평균 − 4단(+0.030, 0.004 ~ 0.058) 하나뿐이었다. 이는 다중 비교 보정이 없는 보조 비교이고 프로브 − 4단(+0.023)과 비슷한 크기여서 새 발견으로 보고하지 않는다.

1,500개 episode에서의 구간 보정(사후). 실제 라벨을 쓰기 전에 파이프라인만 확인하려고 episode 사이에서 라벨을 섞어 smoke를 돌렸더니, 위 해석 규칙이 우연으로도 충족될 수 있었다. 순열 한 번에서 프롬프트 전체 평균이 0.540(0.510 ~ 0.570), 마지막 프롬프트 토큰과의 차이가 +0.046(0.022 ~ 0.070)이었다. 그래서 실제 라벨 분석 전에 순열 10회(episode 사이에서 라벨을 섞고 cross-fit 전체를 다시 하며 점추정만 계산)를 버그 점검과 귀무 크기 확인용으로 추가했고, 차이가 귀무 10개 값을 모두 넘지 못하면 귀무 변동 안에 있다고 함께 적는다는 규칙을 더했다. 위치 비교 중 귀무 10개를 넘은 것은 없었다. 귀무 차이는 0 근처를 중심으로 했고(평균 -0.018 ~ $+0.010$) 표준편차는 0.012–0.025였다. 1,500개 전체에서 이는 같은 비교의 실제 라벨 장면 단위 bootstrap 구간이 뜻하는 표준오차의 1.3–2.6배(중앙값 약 1.8)였다(실행 뒤 계산). 순열이 10회라 이 배율 자체가 부정확하고 순열 귀무와 bootstrap은 다른 양을 다루지만, 1,500개 episode 분석의 장면 단위 구간이 너무 좁다는 쪽을 가리킨다. 더 적은 episode에서 게임 단위와 과제 수준 구간이 그랬던 것과 같다. 이는 4단과의 비교에서 0을 벗어난 사후 구간을 약하게 만들지만, 차이가 탐지되지 않았다는 결과에는 영향이 없다. 구간이 넓어지면 그 결과는 더 강해질 뿐이다.

신경망 텍스트 인코더. TF-IDF 대신 같은 프롬프트의 문장 인코더 임베딩(bge-base-en-v1.5; 510 토큰 조각의 평균)을 쓰면 단독 0.594, 4단 특징과 함께 0.637로 5단보다 -0.115(-0.187 ~ -0.052) 낮았다. 이 인코더 설정은 TF-IDF보다 약했으므로 더 강한 텍스트 baseline이 있는지는 이것으로 시험되지 않았고, 프로브가 이보다 높았던 것(+0.090, 0.039 ~ 0.142)도 프로브가 신경망 텍스트 baseline을 넘는다는 근거가 아니다.

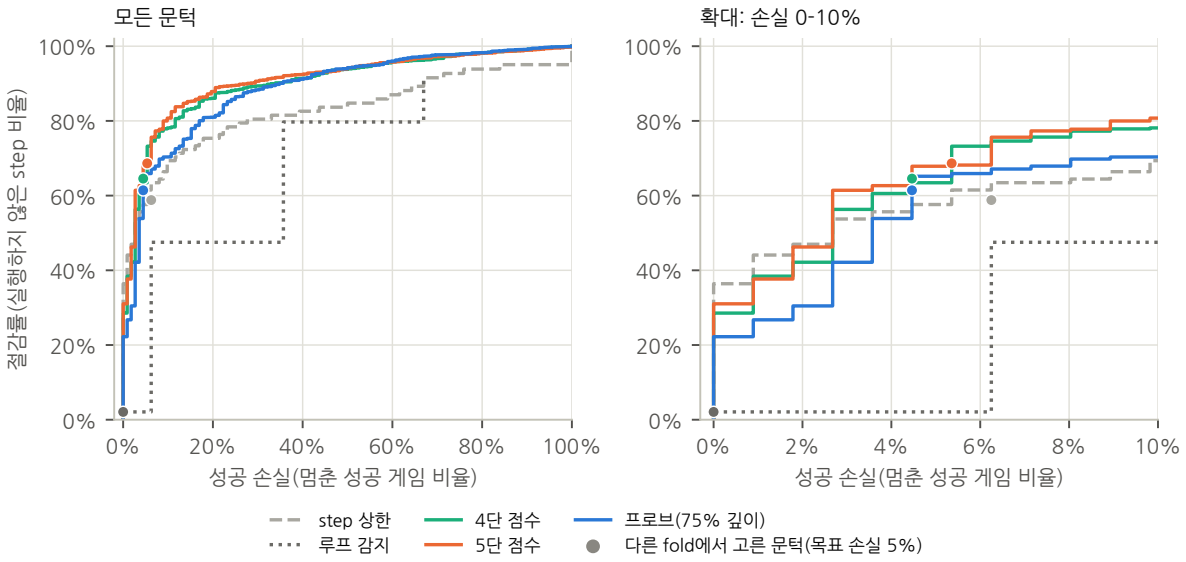


그림 4: 조기 중단 결과의 탐색적 그림(4.6절): 규칙별 성공 손실 대 절감한 step 비율(Qwen2.5-3B, 500게임, 100 action 상한). 왼쪽: 모든 문턱, 오른쪽: 손실 10%까지. 점: 다른 fold에서 목표 손실 5%로 고른 문턱. 프로브는 75% 깊이 프로브에 step 번호를 더한 것이다. 곡선은 평가 데이터에서 문턱을 바꿔 가며 그렸다.

표 8: Exploratory: additional checks, the question each answers, and whether the conclusion changes.

Check	Question	Result (mean over steps 0–2, 95% CI)	Conclusion changed?
Training-set size	Does the gap to rung 5 close with more training data?	75% probe − rung 5, first 250: −0.002 (about 50 training episodes) to −0.025 (about 200); all 500 with fixed evaluation folds: +0.016 (about 50) to +0.006 (about 400), change −0.010 (−0.038, 0.022); all 1,500 (500 + 1,000 new) with fixed evaluation folds: +0.016 (about 50), +0.002 (about 400), −0.006 (about 1,200), change from about 400 to about 1,200 −0.008 (−0.017, 0.002); all CIs include zero	No narrowing detected up to about 1,200 episodes (CI of the change −0.017 to +0.002)
Low false-positive region	Is the probe better where stopping matters?	Detection at 10% false positives, probe − rung 5: −0.139 (−0.273, 0.075)	No
Split unit	Does splitting by game inflate the real methods?	Game − scene split: −0.006 (probe), −0.027 (rung 5)	No
Interval coverage	Are task-level intervals too narrow?	Shuffled-label coverage 90.0% (probe), 85.0% (rung 5), 88.3% (difference); on 1,500 episodes (post hoc, 10 permutations) the null standard deviation was 1.3–2.6 times the bootstrap standard error	No; pre-registered step 1 only narrowly below zero after widening; post hoc intervals on 1,500 episodes are likely too narrow
Reading position	Does the position read change the result?	75% action token − rung 5: −0.019 (−0.085, 0.046); five prompt positions (post hoc, 1,500 episodes): position − last prompt token −0.014 to +0.008, position − rung 5 −0.020 to +0.002, all CIs include zero	No
Text encoder	Is there a stronger text baseline?	bge embedding + rung 4 − rung 5: −0.115 (−0.187, −0.052)	Not answered; this encoder was weaker than TF-IDF

표 9: Exploratory: additional checks on the first 250 episodes unless stated (mean over steps 0–2; AUROC unless stated).

Check	A vs. B	A	B	A − B (95% CI)
Training data 25%	75% probe vs. rung 5	0.681	0.684	−0.002 (−0.044, 0.036)
Training data 50%	75% probe vs. rung 5	0.703	0.714	−0.011 (−0.053, 0.027)
Training data 75%	75% probe vs. rung 5	0.712	0.733	−0.021 (−0.062, 0.020)
Training data 100%	75% probe vs. rung 5	0.727	0.752	−0.025 (−0.077, 0.029)
Training data 25%	50% probe vs. rung 5	0.580	0.684	−0.104 (−0.152, −0.055)
Training data 50%	50% probe vs. rung 5	0.582	0.714	−0.132 (−0.183, −0.076)
Training data 75%	50% probe vs. rung 5	0.600	0.733	−0.133 (−0.185, −0.075)
Training data 100%	50% probe vs. rung 5	0.594	0.752	−0.158 (−0.216, −0.090)
All 500 episodes, training about 50	75% probe vs. rung 5	0.651	0.635	+0.016 (−0.018, 0.049)
All 500 episodes, training about 400	75% probe vs. rung 5	0.707	0.701	+0.006 (−0.024, 0.037)
All 1,500 episodes, training about 50	75% probe vs. rung 5	0.652	0.636	+0.016 (−0.005, 0.035)
All 1,500 episodes, training about 400	75% probe vs. rung 5	0.730	0.728	+0.002 (−0.016, 0.021)
All 1,500 episodes, training about 1,200	75% probe vs. rung 5	0.742	0.747	−0.006 (−0.024, 0.013)
All 1,500 episodes, change from about 400 to about 1,200	75% probe − rung 5	–	–	−0.008 (−0.017, 0.002)
New 1,000 episodes only, training about 400	75% probe vs. rung 5	–	–	−0.000 (−0.022, 0.022)
New 1,000 episodes only, training about 1,200	75% probe vs. rung 5	–	–	−0.014 (−0.037, 0.010)
Post hoc, all 1,500, training about 50	75% probe vs. rung 4	0.652	0.628	+0.024 (0.004, 0.044)
Post hoc, all 1,500, training about 400	75% probe vs. rung 4	0.730	0.706	+0.024 (−0.001, 0.049)
Post hoc, all 1,500, training about 1,200	75% probe vs. rung 4	0.742	0.719	+0.023 (−0.004, 0.049)
Post hoc, all 1,500, training about 50	Rung 5 vs. rung 4	0.636	0.628	+0.008 (0.001, 0.014)
Post hoc, all 1,500, training about 400	Rung 5 vs. rung 4	0.728	0.706	+0.022 (0.009, 0.035)
Post hoc, all 1,500, training about 1,200	Rung 5 vs. rung 4	0.747	0.719	+0.028 (0.011, 0.045)
Post hoc, all 1,500, positions (75%)	C1 `assistant` token vs. last prompt token	0.727	0.742	−0.014 (−0.029, 0.001)
Post hoc, all 1,500, positions (75%)	C2 end of latest observation vs. last prompt token	0.739	0.742	−0.002 (−0.018, 0.013)
Post hoc, all 1,500, positions (75%)	C3 mean of latest observation vs. last prompt token	0.731	0.742	−0.011 (−0.028, 0.007)
Post hoc, all 1,500, positions (75%)	C4 mean of history vs. last prompt token	0.749	0.742	+0.008 (−0.008, 0.023)
Post hoc, all 1,500, positions (75%)	C5 mean of whole prompt vs. last prompt token	0.736	0.742	−0.006 (−0.027, 0.017)
Post hoc, all 1,500, positions (75%)	C1 vs. rung 5	0.727	0.747	−0.020 (−0.040, 0.000)
Post hoc, all 1,500, positions (75%)	C2 vs. rung 5	0.739	0.747	−0.008 (−0.025, 0.010)
Post hoc, all 1,500, positions (75%)	C3 vs. rung 5	0.731	0.747	−0.017 (−0.033, 0.002)
Post hoc, all 1,500, positions (75%)	C4 vs. rung 5	0.749	0.747	+0.002 (−0.014, 0.020)
Post hoc, all 1,500, positions (75%)	C5 vs. rung 5	0.736	0.747	−0.012 (−0.032, 0.010)
Detection at 5% false positives	75% probe vs. rung 5	0.149	0.215	−0.065 (−0.261, 0.087)

5 토의

결과가 보여 주는 것. 과제 수준 평가 네 가지(사전 등록, 확증, 두 번째 Qwen 모델, 두 번째 프롬프트)에서 actor hidden state의 선형 프로브는 프롬프트에 보이는 정보로 만든 baseline보다 나은 적이 없었고, 사전 등록 조건에서는 더 낮았다. 조기 중단 분석도 실용적 측면에서 같은 결과를 보였다. 같은 성공 손실에서 프로브는 고정 step 상한보다 step을 더 아끼지 못했고, 보조 분석에서는 겉보기 baseline에 미치지 못했다. 어느 방법이든 게임 간에 예측한 것의 대부분은 게임 자체였다(샘플링 데이터에서 $\eta^2 = 0.695$, 합친 행에서 난이도 오라클 단독 0.877). 게임 안에서는 step 2부터 모든 방법이 실패 시도와 성공 시도를 우연보다 잘 구분했다. 즉 진행 중 실패가 보이지 않는 것은 아니며, 텍스트와 진행도 특징에도 똑같이 보이고 hidden state는 그 위에 더하는 것이 없었다. 따라서 가설 H1(hidden state가 겉보기 정보보다 실패를 더 잘 예측한다)은 우리가 점검한 어느 설정에서도 지지되지 않았다.

선행연구와의 관계. 에이전트 hidden state의 프로브가 실패를 일찍 예측하고, 행동 수준 특징만 쓰는 모니터보다 낫다는 보고가 있다 [7]. 그 baseline에는 과제 정보(과제 문장, 과제 유형, 관찰, 진행도)가 없다. 우리 사다리에서는 과제 유형만으로 AUROC 0.603, 5단 전체로 첫 action에서 0.701이었고, 이 사다리 전체와 비교하면 어느 설정에서도 프로브의 우위가 없었다. 그들의 행동 특징을 우리 데이터에서 근사하면 같은 프로브가 0.15–0.19 높았고, 과제 유형만 더해도 그 차이의 일부가 메워졌으며 5단 전체에서는 모두 사라졌다(4.5절). 그들의 환경을 재현하지는 않았으므로 그 환경에서 보고된 이득이 사라진다고 말할 수는 없다. 다만 과제를 보지 못하는 모니터와의 비교는 hidden state가 더하는 정보를 과대평가할 수 있음을 시사한다. 우리 프로브는 읽는 위치도 다르다(action 마지막 토큰이 아니라 프롬프트 마지막 토큰). 다만 action 토큰을 읽어도 탐색 점검에서 결론은 같았고, 1,500개 episode에서 프롬프트 안의 다른 다섯 위치를 읽어도 같았다(사후; 4.8절). 수학 추론에서 Bulut [10]은 초기 hidden state 프로브의 높은 합친 AUROC(0.849)가 문제 안에서는 우연 수준(0.496)으로 떨어진다는 것을 보이고, 초기 신호는 주로 어려운 문제를 알아본다고 주장했다. 우리 에이전트 결과는 앞부분(결과의 대부분이 게임으로 정해짐)에서는 일치하지만 뒷부분에서는 다르다. 게임 안에서도 step 2부터 신호가 우연보다 높았다. 에이전트의 궤적은 방문한 장소나 반복한 action처럼 관찰 가능한 방식으로 갈라지고, 텍스트 baseline과 프로브가 모두 이를 읽을 수 있기 때문으로 보이지만 검정하지는 않았다. 반복 실행한 에이전트에서 텍스트 유사도가 hidden state 유사도보다 실행 간 행동을 더 잘 예측했다는 보고 [9]와, 웹 에이전트에서 겉보기 신호가 내부 신호와 경쟁할 만하다는 보고 [18]는 우리 결과와 일관된다. 이와 독립적으로, 가벼운 TF-IDF 감지기가 LLM 심사 모델보다 에이전트의 거짓 성공 주장을 더 잘 찾았다는 보고도 있다(두 벤치마크에서 과제 분리 AUROC 0.83과 0.95, 지연은 3,300배 낮음) [20]. 이 역시 관찰 가능한 텍스트가 모델 내부에 접근하지 않고도 강한 baseline임을 뒷받침한다. 조기 중단에서는 소프트웨어 공학 에이전트에서도 step 수만 쓰는 대조가 이미 비용의 상당 부분을 아꼈는데 [2], 이는 여기서 step 상한이 강했던 것과 맞는다. 반대로 수학·코딩에서는 생성 전 프로브가 15개 설정 중 각각 14개에서 질문 길이와 TF-IDF보다 높았다 [11]. 우리 텍스트 baseline에는 방 묘사, 관찰, 최근 기록도 들어 있고 과제도 상호작용형이다. 이런 차이가 반대 결과를 설명하는지는 검정하지 않았다. 끝으로 프롬프트 사이에서 프로브가 잘 옮겨 가지 않은 결과는, 진실성 프로브의 기하와 일반화가 프롬프트 템플릿과 지시문에 따라 달라진다는 보고 [21]와 같은 방향이다.

여기서 hidden state가 도움이 되지 않은 이유. 세 가지 설명이 가능하며, 셋째만 탐색적으로 직접 살펴보았다. 우리가 읽는 템플릿 토큰 하나가 프롬프트를 잘 요약하지 못한다는 더 단순한 기술적 설명도 탐색적으로 살펴보았고, 시험한 위치 안에서는 지지되지 않았다(아래). 첫째, 평가한 step에서는 결과가 대부분 게임으로 정해지고, 프롬프트가 이미 과제와 방을 서술하므로 프로브가 쓸 수 있는 정보는 텍스트에도 있다. 둘째, 프로브가 일반적인 실패 상태가 아니라 프롬프트의 형식을 담은 방향을 배울 수 있다. 한 프롬프트에서 학습한 프로브는 다른 프롬프트에서 거의 우연 수준이었다(탐색적; 두 프롬프트는 hidden state를 뽑는 토큰도 다르다). 셋째, fold당 학습 episode가 약 200개(홀드아웃은 약 400개)이고 차원이 2,048이라 정규화한 선형 프로브로는 미세한 신호를 뽑기 어려울 수 있다. 다만 reader, 깊이, 프로브 종류(비선형 포함)의 탐색 조합 96개 중 baseline을 넘은 것도 없었고, 평가 fold를 고정하면 학습 episode 약 50–400개 범위(변화 −0.010, 95% 신뢰구간 −0.038

~ +0.022)와 약 400–1,200개 범위(변화 −0.008, 95% 신뢰구간 −0.017 ~ +0.002; 4.8절) 모두에서 5단과의 격차가 좁아지는 것은 탐지되지 않았다. 뒤쪽 범위에서 두 곡선은 평평해졌으므로(AUROC 프로브 +0.012, 5단 +0.020), 시험한 범위 안에서는 학습 집합의 크기가 이득이 없는 이유를 설명하는 것 같지 않다. 이는 탐색적 해석이다. 마찬가지로 최근 관찰, 이력, 프롬프트 전체의 평균을 포함해 프롬프트의 다른 위치를 읽어도 75% 깊이 AUROC는 0.727–0.749로, 마지막 프롬프트 토큰(0.742)과 5단(0.747)에서 약 0.02 안에 있었고 구분된 차이는 없었다(사후; 4.8절). 따라서 시험한 범위에서는 학습 데이터의 양도 읽는 위치도 이득이 없는 이유를 설명하지 못한다. 첫째·둘째 설명과 actor 자체의 한계는 열려 있다.

보완적 해석. 75% 깊이에서 토큰 하나를 읽고 손으로 만든 특징 없이 fold당 약 200개 episode로 학습한 프로브는, 앞 250개 episode에서 공들여 만든 5단 baseline과 AUROC 0.011–0.034 차이 안에 있었고, 홀드아웃(학습 episode 약 400개)의 step 0과 1에서는 유의하지 않지만 앞섰다. 75% 깊이는 탐색한 깊이들을 본 뒤 고른 최선값이며, 사전 등록한 50% 칸은 5단보다 0.13–0.18 낮았다. 실패와 관련된 정보의 상당 부분이 표현 안에 선형으로 들어 있다는 뜻이다. 평가 행을 고정하면 학습 episode 약 50–400개 범위에서 격차 변화가 탐지되지 않았고(4.8절), 약 400–1,200개 범위에서도 탐지되지 않았다(−0.008, 95% 신뢰구간 −0.017 ~ +0.002, 1,500개 episode). 프로브는 모든 크기에서 5단과 약 0.02 안에 있었고(−0.006 ~ +0.016, 구간은 모두 0 포함), 평균적으로 4단을 약 0.02 앞섰다(사후; 구간이 0을 벗어난 것은 약 50개뿐이고, 이 분석들의 구간은 아마 너무 좁다). 프롬프트의 다른 다섯 읽는 위치도 같은 그림을 보였다(75% 깊이 0.727–0.749). 더 큰 학습 집합에서 이것이 달라지는지는 시험하지 않았다.

실용적 함의. 작은 에이전트가 스스로 모니터를 돌린다면 hidden state는 추가 비용이 없으므로 작은 이득이라도 쓸모가 있다. 그러나 그런 이득은 찾지 못했다. 성공 손실 10% 이하에서 step 상한은 프로브만큼 step을 아꼈고, 겉보기 baseline은 적어도 그만큼 아꼈다. 에이전트의 텍스트를 읽는 모니터나 단순한 상한이 더 싼 출발점이며 모델 내부에 접근할 필요도 없다. hidden state가 낫다는 주장은 같은 과제 정보를 보는 baseline과 비교해 검증해야 한다.

방법론적 시사점. 몇몇 설계 선택은 비슷한 연구에서 결론을 바꿀 수 있다. 방 배치가 아니라 게임 단위로 나누면 장면 정보만 담은 합성 특징의 AUROC가 0.97까지 부풀었다. 실제 프로브와 5단에서는 변화가 작았다(−0.006, −0.027; 4.8절). 게임 내 평가는 아직 갈라지지 않은 rollout 때문에 희석되었다. 쌍의 52–70%가 같은 프롬프트였고, 이는 프롬프트에 기반한 모든 예측의 상한을 낮춘다. 라벨을 섞은 데이터에서 게임 단위 percentile bootstrap 구간은 너무 좁았다(포함률 95%가 아니라 80–94%). 과제 수준 구간은 명목에 더 가까웠다(85–90%; 5단은 명목보다 낮고 프로브는 95%와도 80%와도 구별되지 않음; 4.8절). 1,500개 episode에서는 순열 귀무의 퍼짐이 장면 단위 bootstrap 표준오차의 약 1.3–2.6배였다(순열 10회, 사후). 라벨을 섞은 한 번의 실행이 구간 기반 판정 규칙을 우연히 통과할 수도 있다. 우리 위치 분석에서 실제로 그랬으므로, 실제 라벨을 쓰기 전에 순열을 여러 번 해 보는 것이 값싼 안전장치다. 시도가 갈라지는지는 정책에 달려 있다. $T = 1$로 샘플링한 Qwen3-4B는 50게임 중 10게임에서만 갈라져 시도 수준 질문에 답할 수 없었다. 다른 모델 계열로의 확장은 프롬프트와 모델의 궁합에 막혔다. Qwen 이외 모델 세 개는 우리 프롬프트에서 각각 파일럿 20게임 중 1개만 풀었다.

예상 밖의 결과. 외부 ReAct 형식 프롬프트가 같은 actor의 성공률을 높였다(250게임 중 89개 대 56개). 우리 프롬프트를 이 모델에 맞춰 조정했는데도 그랬다. 여러 요소가 함께 바뀌었으므로 어느 것이 중요했는지는 모른다. 원인이 무엇이든 더 높은 성공률을 낸 프롬프트에서도 프로브는 겉보기 baseline을 넘지 못했다.

6 한계

- **에이전트 설정.** action을 자유 생성이 아니라 가능한 후보의 점수로 골랐으므로 에이전트는 제한된 선택기이다. 자유 생성 에이전트와는 비교하지 않았다.

- **범위.** 환경 하나(ALFWorld)이다. 주 결과는 actor 하나(Qwen2.5-3B)와 프롬프트 하나에서 나왔고, 다른 actor와 두 번째 프롬프트는 따로 보고한다(4.4절). 이 설정 밖으로 일반화하지 않는다.
- **모델.** 모델 확장은 3–4B 크기의 Qwen 모델 2개(Qwen2.5-3B, Qwen3-4B)뿐이다. Qwen 이외 모델 3개(Llama-3.2-3B, SmolLM3-3B, Phi-3.5-mini)와 Qwen3-1.7B는 같은 사전 등록 기준으로 파일럿했으나 각각 20개 중 1개만 성공해 제외했다(부록 표 A1). 주 프롬프트를 Qwen2.5로 조정했으므로 모델 능력보다 프롬프트와 모델의 궁합 때문일 수 있다. 이 두 모델 밖으로 일반화하지 않는다.
- **두 번째 프롬프트.** 프롬프트는 두 개뿐이고, ReAct 예시는 최소로 고쳤으며, 두 프롬프트는 여러 요소가 동시에 다르다. ReAct 프롬프트의 5단 텍스트에는 가능한 action 목록이 없다. ReAct 점검은 Qwen2.5-3B의 과제 수준에서만 했다.
- **조기 중단.** 비용을 토큰이나 지연이 아니라 action 수로 셌고, 3B actor 자신의 hidden state, 탐욕 정책, 100 action 상한만 평가했으며, 앞선 분석에 이미 쓴 게임을 썼다.
- **외부 감시.** 3B 이외의 reader는 다른 모델이 만든 궤적을 읽는다. 7B reader는 4비트로 양자화되어 크기 효과와 교락된다. reader마다 hidden 차원도 달라(896, 1,536, 2,048, 3,584) 학습 episode 대비 차원 비율이 바뀐다.
- **표본 크기.** 평가 집합마다 250개 episode(성공 약 50개)라 AUROC 차이의 신뢰구간이 약 ±0.06–0.10이다. 작은 차이와 reader 크기 효과는 구분하지 못한다. 1,500개 episode(방 배치 108개)에서도 프로브 − 5단의 구간은 약 ±0.02였고 그 폭이 학습 데이터를 늘려도 줄지 않았으므로 0.02 이하의 차이도 구분하지 못한다.
- **사후 선택.** 4.8절의 4단과의 비교와 읽는 위치 비교는 sweep 결과를 읽은 뒤 추가했다. 위치는 위치 분석 실행 전에 고정했고, 순열 점검과 그 규칙은 실제 라벨을 쓰기 전에 추가했다. 75% 깊이와 비열등 마진 0.05는 탐색 분석 뒤에 정했다. 마진은 게임 간 AUROC 기준으로 정한 것이라 시도 수준에서는 척도가 다르다.
- **비교 설계.** TF-IDF와 로지스틱 회귀는 약한 텍스트 baseline이고, 시험한 신경망 텍스트 인코더 하나(같은 프롬프트의 bge-base-en-v1.5 임베딩)는 이보다도 약했으므로(4.8절) 더 강한 텍스트 baseline이 격차를 넓힐지는 열려 있다. 주 프로브는 [7]처럼 action 토큰이 아니라 프롬프트 마지막 토큰을 읽으며, action 토큰을 읽어도 결론이 같다는 것은 앞 250개 episode의 탐색 점검으로만 확인했다. 프롬프트의 다른 다섯 위치는 사후에만 비교했고, actor 하나와 프롬프트 하나에서 위치를 이어 붙이거나 모든 후보 action을 점수화하지 않고 비교했다. 입력에 가까운 25% 깊이의 프로브는 더 약했고(3B reader 0.595; 표 A6), 미세조정한 텍스트 모델은 시도하지 않았다. step 7부터는 4단의 진행도 특징(조기 중단 분석의 4t·5t단도)이 프롬프트에 보이는 최근 6 step보다 오래된 action을 쓴다.
- **지표와 통계.** AUROC는 중단에 중요한 낮은 오탐 구간을 겨냥하지 않는다. 오탐률 5%·10%의 검출률은 탐색 점검에서 AUROC와 같은 방향이었지만 성공 56개에 기대고 있다. 초반 상태로 도달 가능한 AUROC(상한)는 추정하지 않았다. 라벨을 섞은 데이터에서 과제 수준 구간은 귀무값을 95%가 아니라 85–90%만 포함했고(4.8절) 1,500개 episode에서는 순열 귀무가 장면 단위 bootstrap 구간보다 넓었으므로(순열 10회) 일부는 시도 수준 구간처럼 좁을 수 있고(대략 보정하면 사전 등록 차이의 step 1이 간신히 0 아래), 교차검증 seed 사이의 분산은 구간에 들어 있지 않다. 사전 등록·사전 지정·확증 비교 18개는 게임과 baseline을 공유해 독립이 아니다.
- **등록.** 계획은 외부 등록처가 아니라 프로젝트 저장소의 날짜 있는 commit으로 등록했다. 벗어난 점과 이른 노출은 부록 표 A8에 적었다.
- **하지 않은 것.** 두 번째 환경은 등록한 계획 밖의 새 수집이 필요해 넣지 않았다. 동등성 마진을 등록하지 않았으므로(0.05 비열등 마진은 탐색 뒤에 정함) 정식 동등성 분석은 하지 않았다(4.8절의 마진 표는 기술용이며 이를 대신하지 않는다). 각 상태에서의 성공 확률(Monte Carlo value 타깃)은 같은 prefix에서 갈라진 여러 continuation, 즉 새 수집이 필요해 추정하지 않았

다. 약 1,200개를 넘는 학습 집합도 시도하지 않았다(1,000개 episode는 표본 확대 금지 규칙의 등록된 예외로 추가했다; 4.8절). 더 큰 집합에 대해서는 주장하지 않는다.

- **정책 차이.** 시도 수준 결과는 과제 수준의 탐욕 정책이 아니라 샘플링 정책($T = 1$)에서 나왔고, 게임은 탐욕 결과로 골랐다.
- **초반 라운드.** 사전 등록한 라운드는 처음 세 action뿐이다. 후반 라운드는 생존에 조건부이며 탐색적으로만 분석했다.
- **절단.** episode를 30 action에서 끊었으므로 라벨은 "30 action 안에 풀지 못함"을 뜻한다. 탐욕 실패 399개를 100 action까지 다시 돌리면 2.8%(95% CI 1.6–4.9%)가 늦게 성공했고, 100 action 라벨에서도 결론은 바뀌지 않았다(4.7절). 시도 수준 라벨은 100 action으로 다시 점검하지 않았다.
- **프롬프트 조정.** 주 프롬프트는 ReAct의 생각–행동 형식에서 출발해 직접 작성했고, 데이터 수집 전에 다른 분할(valid_unseen)의 episode를 보며 고쳤다. 외부 프롬프트(ReAct 예시)는 4.4절에서 점검한다.

7 결론

텍스트 기반 가정 환경에서 소형 Qwen 에이전트의 hidden state에 학습한 선형 프로브는, 과제·프롬프트 텍스트·단순한 진행도 특징으로 만든 baseline보다 실패를 더 잘 예측하지 못했다. 사전 등록 분석, 홀드아웃, 두 번째 모델, 외부 프롬프트 어디에서도 마찬가지였다. 탐욕 결과로 층화한 우리 표본에서 초반의 실패는 대체로 시도가 아니라 게임의 성질이었고, 게임 안에서 생겨난 실패도 텍스트에서 똑같이 보였다. 성공 손실 10% 이하에서 프로브로 실패할 episode를 멈추는 것이 고정 step 상한보다 step을 더 아낀다는 것은 보이지 않았다. 따라서 hidden state가 에이전트의 실패를 드러낸다는 주장은 같은 과제 정보를 보는 baseline과 비교하고, 과제 안에서 평가해 검증해야 한다.

코드와 데이터 공개

코드, 설정, 각 실행 전에 고정한 분석 계획(날짜 포함), 보고한 수치를 낸 결과 표, 그림 스크립트는 공개 저장소에 있다(심사를 위해 링크 생략). 수집한 궤적과 hidden state(3.6 GB)는 용량 때문에 저장소에 없다.

참고문헌

[1] D. Pham, K. Katevas, A. S. Shamsabadi, and H. Haddadi. AgentStop: Terminating local AI agents early to save energy in consumer devices. In *ACM CAIS*, 2026. arXiv:2605.15206.

[2] C. Wang, Y. Lyu, J. He, Z. Yang, C. Zhong, Y. Harel, and D. Lo. Fail-fast, restart-smart: Early failure prediction and restart for SWE agentic tasks, 2026. arXiv:2608.03222.

[3] S. Kadavath et al. Language models (mostly) know what they know, 2022. arXiv:2207.05221.

[4] L. Kuhn, Y. Gal, and S. Farquhar. Semantic uncertainty: Linguistic invariances for uncertainty estimation in natural language generation. In *International Conference on Learning Representations* (*ICLR*), 2023.

[5] J. Kossen, J. Han, M. Razzak, L. Schut, S. Malik, and Y. Gal. Semantic entropy probes: Robust and cheap hallucination detection in LLMs, 2024. arXiv:2406.15927.

[6] I. V. Moreno Cencerrado, A. Padrés Masdemont, et al. No answer needed: Predicting LLM answer accuracy from question-only linear probes. In *ICLR 2026 Workshop: Principled Design for Trustworthy AI*, 2026. arXiv:2509.10625.

[7] K. Ruan, Z. Huang, Z. Zhou, Q. Wei, J. Lin, X. Wang, and H. Sun. Doomed from the start: Early abort of LLM agent episodes via a recall-controlled probe cascade, 2026. arXiv:2607.06503v2.

[8] Y. Shi, Z. Sun, J. Dong, C. Wan, D. Lo, and X. Gu. EarlyEval: Cheaper agent evaluation via early outcome prediction, 2026. arXiv:2609.02783.

[9] A. Mehta and A. Datta. When agents commit too soon: Diagnosing premature commitment in LLM agents, 2026. arXiv:2606.22936v2.

[10] Y. U. Bulut. It's the problem, not the path: Budget and difficulty confounds in LLM reasoning trajectories, 2026. arXiv:2609.03436.

[11] W. Lugoloobi, T. Foster, W. Bankes, and C. Russell. LLMs encode their failures: Predicting success from pre-generation activations. In *Conference on Language Modeling* (*COLM*), 2026. arXiv:2602.09924.

[12] M. Shridhar, X. Yuan, M.-A. Côté, Y. Bisk, A. Trischler, and M. Hausknecht. ALFWorld: Aligning text and embodied environments for interactive learning. In *International Conference on Learning Representations* (*ICLR*), 2021.

[13] S. Yao et al. ReAct: Synergizing reasoning and acting in language models. In *International Conference on Learning Representations* (*ICLR*), 2023.

[14] C. Burns, H. Ye, D. Klein, and J. Steinhardt. Discovering latent knowledge in language models without supervision, 2022. arXiv:2212.03827.

[15] S. Marks and M. Tegmark. The geometry of truth: Emergent linear structure in large language model representations of true/false datasets. In *Conference on Language Modeling* (*COLM*), 2024. arXiv:2310.06824.

[16] A. Ghasemabadi and D. Niu. Can LLMs predict their own failures? self-awareness via internal circuits, 2025. arXiv:2512.20578.

[17] R. Khan and N. I. Khan. The cognitive companion: A lightweight parallel monitoring architecture for detecting and recovering from reasoning degradation in LLM agents, 2026. arXiv:2604.13759.

[18] S. Pan, Y. Shen, Y. Lu, C. Ding, et al. Monitoring web agents without internal signals: Observable trajectories and key-step supervision, 2026. arXiv:2609.02057.

[19] S. Dubey. Real-time detection and repair of LLM agent failures, 2026. arXiv:2608.02464.

[20] L. Advani. From confident closing to silent failure: Characterizing false success in LLM agents, 2026. arXiv:2606.09863.

[21] A. Poulis, M. Crovella, and E. Terzi. Testing the limits of truth directions in LLMs, 2026. arXiv:2604.03754v2.

A 부록 표

표 A1: Model pilots (first 20 games, v2 prompt, candidate scoring, 30 actions).

Model	Successes (Wilson 95% CI)	s / episode	Peak GPU memory	Decision
Qwen3-4B (thinking off)	7/20 (18–57%)	14.9	10.24 GB	included
Qwen3-1.7B (thinking off)	1/20 (1–24%)	8.5	5.03 GB	excluded (successes)
Llama-3.2-3B-Instruct	1/20 (1–24%)	10.7	8.06 GB	excluded (successes)
SmolLM3-3B	1/20 (1–24%)	10.4	7.41 GB	excluded (successes)
Phi-3.5-mini-instruct (candidates scored in batches of 4)	1/20 (1–24%)	67.6	10.75 GB	excluded (successes, time)

같은 게임에서 Qwen2.5-3B는 5/20이었다(참고). 모든 실행이 끝까지 돌았고, 모든 action이 가능한 action이었으며, hidden state에 NaN·inf가 없었다. revision을 고정했고 chat template의 날짜도 고정했다(Llama "26 Jul 2024", SmolLM3 "20 October 2026").

표 A2: Exploratory: action patterns on the 20 pilot games.

Model	Successes	Repeated within last 6 steps	Distinct-action ratio	Most frequent verbs
Qwen2.5-3B	5/20	51%	0.44	go 67%, take 11%, move 8%
Qwen3-4B	7/20	32%	0.54	go 60%, examine 14%, open 9%
Llama-3.2-3B	1/20	66%	0.26	examine 47%, go 28%, open 12%
SmolLM3-3B	1/20	82%	0.19	examine 57%, take 15%, move 14%
Phi-3.5-mini	1/20	76%	0.25	take 33%, move 30%, go 16%

표 A3: Qwen3-4B within-game pairwise AUROC ($T = 1$ sampling; 10 of 50 games with both outcomes, 120 pairs per step).

	Step 1	Step 2	Step 3
Probe (own hidden state, 75% depth, linear)	0.471 (0.396, 0.500)	0.471 (0.397, 0.509)	0.479 (0.402, 0.517)
Rung 4	0.479 (0.404, 0.519)	0.471 (0.397, 0.509)	0.521 (0.443, 0.611)
Rung 5	0.471 (0.391, 0.508)	0.471 (0.397, 0.509)	0.521 (0.443, 0.611)
Probe − rung 4 (95% CI)	−0.008 (−0.020, 0.000)	0.000 (0.000, 0.000)	−0.042 (−0.202, +0.063)
Probe − rung 5 (95% CI)	0.000 (−0.011, +0.015)	0.000 (0.000, 0.000)	−0.042 (−0.202, +0.063)
Within-game permutation p, probe	1.00	0.94	0.92

게임 단위 bootstrap(1,000회). $\eta^2 = 0.849$(0.747–0.935), 합친 행에서 난이도 오라클 단독 0.911. 쌍 대부분이 동점(같은 프롬프트)이라 이 값들은 정보가 적으며, 결과를 읽기 전에 정한 대로 결론을 내지 않는다(4.4절).

표 A4: The two prompts.

	v2 (ours)	ReAct exemplars (minimally edited)
Source	Written by us; earlier version in ReAct thought–action format; frozen before data collection	Yao et al. (2023), `alfworld_3prompts.json`, repository commit `6bdb3a1`
Format	Chat template (system + user message)	Raw completion text ending in `>`
Instructions	Six rules	One header line
Exemplars	One handwritten episode (clean task), same for all tasks	Two original episodes matched to the current task type, including `think:` lines
History	Last six steps	Full episode
Admissible actions in prompt	Yes, plus recently failed actions	No (scoring still restricted to admissible actions)
Scored continuation	`Action: a<|im_end|>`	`␣a\n`
Hidden-state token	Last token of the generation prompt	Final `>`
Edits	–	`put A in/on B` → `move A to B` and the matching observation
Length (Qwen2.5 tokens)	median 864 (whole prompt)	1,115–1,571 (exemplars only)

표 A5: Preliminary runs before the policy was fixed (2026-10-08).

Run	Episodes	Successes	Admissible actions
Free generation, first prompt (Thought/Action), 0.5B	2	0	8%
Free generation, first prompt, 1.5B	5	0	56%
Free generation, first prompt, 3B	5	1	61%
Free generation, 1.5B, first code on the GPU machine	3	0	26%
Free generation, 1.5B, revised prompt (rules and example)	5	0	22%
Candidate scoring (final policy), 0.5B / 1.5B / 3B, training games	20 / 100 / 100	0 / 2 / 20	100% by construction

자유 생성 실행은 프롬프트를 동결하기 전에 ALFWorld train 게임에서 Qwen2.5-Instruct 모델로 했다. episode가 매우 적어, 목록에 없는 action이 자주 나왔다는 것만 보여 준다. 출처: 2026-10-08 프로젝트 기록. 실행 원 로그는 저장소와 그 백업 어디에도 남아 있지 않다.

표 A6: Exploratory: linear-probe AUROC by reader and depth, first 250 episodes, mean over steps 0–2.

Reader	25%	50%	75%	100%	Probe − rung 5, all 24 cells per reader (min, max)
0.5B	0.618	0.615	**0.660**	0.642	−0.277, +0.001
1.5B	0.589	0.631	**0.717**	0.675	−0.195, −0.006
3B (= actor)	0.595	0.594	**0.727**	0.682	−0.205, +0.004
7B (4-bit)	0.608	0.643	0.704	**0.717**	−0.191, −0.004

5단은 step 0–2 평균 0.752였다. 마지막 열은 네 깊이·세 step의 선형·MLP 프로브를 모두 포함한다(reader당 24칸, 모두 96칸). 굵은 글씨는 reader별 최고 깊이이다. 3B reader 50% 깊이가 사전 등록 조건이다(표 1). 96칸 모두의 차이와 95% CI는 표 A9에 있다.

표 A7: Pre-registered hypothesis, decision rules and interpretation tables (wording from the frozen plans).

Pre-registered item	Fixed	Observed
Task level. H1: on 3B trajectories with the 3B reader, the probe AUROC at rounds 1–3 is higher than rung 5 (95% CI of the difference excludes zero, above).	Before the primary run (2026-10-15)	Not supported: all three differences below zero
Interpretation (a): only the 3B reader beats rung 5 → readable information has a size boundary. (b): all reader sizes beat it similarly → the information is at text level, so small models read it too. (c): even the 3B reader does not beat it → visible information suffices in this setting (negative result).	Before the primary run	(c)
Decision rule for a difference: superior if the lower 95% bound > 0; non-inferior if it > -0.05; inferior if the upper bound < 0; otherwise inconclusive. The 0.05 margin was set after the exploratory analysis.	Margin: after exploration, before the hold-out was evaluated	Hold-out: non-inferior, non-inferior, inconclusive (Table 2)
Attempt level. Probe > rungs 4 and 5 (lower 95% bound > 0) → hidden states carry an in-progress failure signal not explained by difficulty text. Probe ≈ baseline → a signal exists but adds nothing beyond the history. All near 0.5 → success and failure within a game are not predicted by these methods.	Before the sampled rollouts were collected	Fits no row cleanly (Section 4.2)
Supplementary rules for the attempt level: "≈" only if the 95% CI of the difference lies within ± 0.05 (a lower bound above -0.05 alone is "non-inferior, weak"); "near 0.5" if the CI includes 0.5 and the within-game permutation $p > 0.05$; Holm adjustment over the six comparisons.	Before the attempt-level results were opened (2026-10-17)	No comparison superior or equivalent

표 A8: Deviations from the registered plans and exposures to results before a decision.

Plan	Change or exposure	When	Effect on reported results
Task-level freeze	Sample size raised from 250 to 500 episodes to create the confirmatory hold-out; policy, prompt and code unchanged	2026-10-15, before the hold-out was collected	Hold-out analysed as one separate comparison
Task-level freeze	Repository history rewritten to clean commit messages; the frozen commit hash changed (tree identical, mapping kept)	2026-10-15	None on data or code; registration rests on dated commits and the mapping
Confirmatory comparison	Non-inferiority margin 0.05 chosen after the exploratory analysis	Before the hold-out was evaluated	Non-inferior labels are weak (Table 2 note)
Attempt level	Games stratified by greedy outcome, decided after the pilot	Before the main set was collected	Variance explained by the game is not a population value
Attempt level	Supplementary analyses and interpretation rules added (equivalence band, near-0.5 rule, Holm adjustment)	2026-10-17, before the results were opened	Primary verdicts reported unchanged; rules applied in addition
Attempt level	Another session saw the first two lines of the results log (run size and the η^2 point estimate)	Before the attempt-level results were opened	Reported; no other result was seen
100-action re-run	Interim counts seen twice during collection (3 late successes among the first 116 games); a partial collection was discarded after a shutdown	2026-10-17, before the decision	Decision rule unchanged (committed beforehand)
Early termination	Loop-detector definition clarified, then corrected so that the count excludes the action itself	2026-10-20, before code was run and results opened	None on the other rules
Model extension	Inclusion rule changed so that every model passing the pilot criteria enters	2026-10-20, before the SmolLM3 pilot	Substitutes cannot be chosen after results; no further models added
Model pilots	Reference time of the time criterion was not defined; judged against a reference value	2026-10-17, after the first pilots	Exclusions rest on the success criterion
Second prompt (ReAct)	Methods of the secondary success-rate comparison (Wilson CI, game-level bootstrap, exact McNemar) were not in the plan	2026-10-20, fixed in the script before running	Secondary result only
Additional checks	Six exploratory checks (training-set size, low false-positive region, split unit, interval coverage, action-token position, text encoder) planned after the pre-registered, confirmatory and exploratory results had been read	2026-10-21, plan fixed before each check was run	Exploratory only; no verdict changed
Training-size sweep	Sweep on all 500 episodes reuses the confirmatory hold-out for training and evaluation; planned after the first-250 learning curve and the hold-out results had been read	2026-10-21, plan fixed before the run	Exploratory only; the confirmatory verdict is unchanged
Training-size sweep (1,500 episodes)	1,000 new greedy episodes collected as an exception to the rule against enlarging samples; plan (sizes, primary contrast, interpretation rules) planned after the 500-episode sweep and the earlier results had been read	2026-10-21, approved before collection	Exploratory only; the confirmatory verdict is unchanged
Training-size sweep (1,500 episodes)	Plan extended by an equivalence-margin table (0.02, 0.05, 0.10) and an evaluation on the 1,000 new episodes only, in anticipation of review questions; no margin was registered	2026-10-23, before the new data were analysed	Descriptive; primary contrast and interpretation rules unchanged
Exposure	The win/loss lines of an interrupted collection of 39	2026-10-23; the	Primary contrast

표 A9: Exploratory: probe − rung 5 AUROC difference (95% CI) for all 96 cells (4 readers × 2 probe types × 4 depths × 3 steps), first 250 episodes.

Reader	Probe	Depth	Step 0	Step 1	Step 2
0.5B reader	Linear	25%	−0.136 (−0.236, −0.037)	−0.159 (−0.253, −0.061)	−0.106 (−0.191, −0.012)
0.5B reader	Linear	50%	−0.168 (−0.273, −0.065)	−0.112 (−0.223, −0.010)	−0.133 (−0.209, −0.049)
0.5B reader	Linear	75%	−0.130 (−0.212, −0.054)	+0.001 (−0.085, 0.087)	−0.148 (−0.229, −0.067)
0.5B reader	Linear	100%	−0.062 (−0.130, 0.002)	−0.050 (−0.125, 0.029)	−0.218 (−0.299, −0.131)
0.5B reader	MLP	25%	−0.259 (−0.386, −0.124)	−0.190 (−0.283, −0.078)	−0.277 (−0.373, −0.168)
0.5B reader	MLP	50%	−0.160 (−0.245, −0.083)	−0.160 (−0.272, −0.044)	−0.144 (−0.216, −0.063)
0.5B reader	MLP	75%	−0.163 (−0.242, −0.090)	−0.068 (−0.155, 0.021)	−0.154 (−0.232, −0.077)
0.5B reader	MLP	100%	−0.100 (−0.177, −0.025)	−0.012 (−0.096, 0.075)	−0.151 (−0.235, −0.071)
1.5B reader	Linear	25%	−0.155 (−0.231, −0.079)	−0.155 (−0.237, −0.075)	−0.179 (−0.274, −0.084)
1.5B reader	Linear	50%	−0.104 (−0.178, −0.032)	−0.113 (−0.201, −0.020)	−0.146 (−0.231, −0.066)
1.5B reader	Linear	75%	−0.074 (−0.154, −0.006)	−0.006 (−0.074, 0.071)	−0.025 (−0.097, 0.047)
1.5B reader	Linear	100%	−0.105 (−0.188, −0.024)	−0.055 (−0.129, 0.023)	−0.069 (−0.135, −0.004)
1.5B reader	MLP	25%	−0.173 (−0.261, −0.080)	−0.170 (−0.247, −0.094)	−0.161 (−0.241, −0.081)
1.5B reader	MLP	50%	−0.195 (−0.293, −0.086)	−0.074 (−0.163, 0.017)	−0.138 (−0.232, −0.058)
1.5B reader	MLP	75%	−0.167 (−0.240, −0.089)	−0.086 (−0.177, 0.003)	−0.069 (−0.135, −0.003)
1.5B reader	MLP	100%	−0.091 (−0.174, −0.007)	−0.097 (−0.185, −0.003)	−0.121 (−0.208, −0.035)
3B reader (= actor)	Linear	25%	−0.127 (−0.206, −0.061)	−0.176 (−0.269, −0.080)	−0.169 (−0.244, −0.087)
3B reader (= actor)	Linear	50%	−0.181 (−0.276, −0.069)	−0.133 (−0.230, −0.031)	−0.159 (−0.240, −0.073)
3B reader (= actor)	Linear	75%	−0.034 (−0.102, 0.037)	−0.011 (−0.082, 0.061)	−0.029 (−0.091, 0.027)
3B reader (= actor)	Linear	100%	−0.120 (−0.196, −0.056)	−0.057 (−0.147, 0.032)	−0.034 (−0.098, 0.027)
3B reader (= actor)	MLP	25%	−0.163 (−0.245, −0.075)	−0.153 (−0.259, −0.048)	−0.205 (−0.292, −0.105)
3B reader (= actor)	MLP	50%	−0.198 (−0.295, −0.106)	−0.189 (−0.290, −0.089)	−0.145 (−0.227, −0.063)
3B reader (= actor)	MLP	75%	+0.004 (−0.050, 0.061)	0.000 (−0.069, 0.069)	−0.036 (−0.098, 0.025)
3B reader (= actor)	MLP	100%	−0.095 (−0.168, −0.025)	−0.057 (−0.145, 0.031)	−0.038 (−0.097, 0.021)
7B reader (4-bit)	Linear	25%	−0.107 (−0.208, −0.005)	−0.136 (−0.215, −0.051)	−0.189 (−0.277, −0.104)
7B reader (4-bit)	Linear	50%	−0.099 (−0.177, −0.019)	−0.053 (−0.141, 0.032)	−0.175 (−0.251, −0.097)
7B reader (4-bit)	Linear	75%	−0.119 (−0.189, −0.048)	−0.004 (−0.094, 0.093)	−0.021 (−0.080, 0.046)
7B reader (4-bit)	Linear	100%	−0.058 (−0.141, 0.022)	−0.030 (−0.113, 0.056)	−0.017 (−0.080, 0.050)
7B reader (4-bit)	MLP	25%	−0.154 (−0.251, −0.051)	−0.132 (−0.232, −0.028)	−0.144 (−0.229, −0.060)
7B reader (4-bit)	MLP	50%	−0.191 (−0.286, −0.096)	−0.122 (−0.221, −0.021)	−0.149 (−0.226, −0.072)
7B reader (4-bit)	MLP	75%	−0.124 (−0.216, −0.036)	−0.079 (−0.162, 0.011)	−0.094 (−0.170, −0.020)
7B reader (4-bit)	MLP	100%	−0.071 (−0.158, 0.012)	−0.087 (−0.177, 0.001)	−0.039 (−0.115, 0.031)

장면 단위 cluster bootstrap 1,000회. step당 $n = 250$(실패 194). 7B reader는 4비트 가중치를 썼다. 3B reader의 50% 깊이 선형 칸이 사전 등록 조건이다.