

연구 계획서

소형 언어모델 에이전트의 실패 신호 스케일링 연구

— 모델 규모에 따른 내부 표현의 예측 가능성 저하 분석과 경량 결합을 통한 보완

I. 연구의 배경 및 필요성

1. 연구 배경

에이전트 시스템의 설계는 단일 대형 모델을 최대 성능으로 사용하는 방식에서, 비용·지연시간·프라이버시 요구에 맞추어 더 작은 모델을 반복적으로 호출하는 방향으로 확장되고 있다. 특히 온디바이스 환경이나 개인 장치에서 동작하는 에이전트는 제한된 메모리와 연산 자원 안에서 행동 계획, 도구 선택, 환경 관찰 해석을 반복해야 하므로 소형 언어모델의 실질적인 활용 가능성이 중요하다.

한편 에이전트의 실패를 사후 분석하는 대신 실행 중에 조기 감지하려는 연구도 활발하다. Ruan 등(2026)은 에이전트 상호작용 라운드마다 hidden activation에 프로브를 적용하여 최종 episode failure를 일찍 예측하고, 사용자가 지정한 성공 episode 보존 재현율을 만족하도록 조기 중단 cascade를 구성하였다. 이 연구는 Qwen2.5-7B와 Llama-3.2-3B에서 내부 표현 기반 조기 중단이 행동 기반 판정보다 더 많은 추론 비용을 절감할 수 있음을 보였다.

또한 Padhi 등(2026)은 ALFWorld와 ScienceWorld에서 단계별 내부 표현을 conformal prediction과 결합해 성공·실패·추론 이탈과 관련된 시간적 개념 방향을 추출하였으며, Nordby 등(2026)은 0.5B부터 176B까지 다양한 모델에서 linear probe 정확도가 모델 규모와 함께 증가하고 다층 앙상블이 단일 계층 프로브의 취약성을 완화할 수 있음을 보고하였다. 다만 후자의 주 대상은 기만 탐지와 같은 단발성 판별이며, 다단계 에이전트 궤적의 최종 실패와는 문제 구조가 다르다.

2. 문제 제기

현재 확인된 선행연구를 종합하면, '3B 이하 모델에서 실패 예측 프로브가 전혀 검증되지 않았다'고 주장하는 것은 정확하지 않다. 이미 3B 모델을 포함한 실험이 존재하기 때문이다. 본 연구가 다루는 보다 정확한 공백은 동일 모델 계열을 0.5B·1.5B·3B로 체계적으로 축소하며 failure-related representation의 scale sensitivity를 비교한 연구가 부족하다는 점이다.

- 검증 범위의 불연속성: 일부 3B 실험은 존재하지만 sub-3B 구간을 동일 계열·동일 과제로 연속 비교한 scaling study는 부족하다.
- 방법론 간 직접 비교의 부재: 라운드 단위, 시간 단위, 계층 단위 프로빙이 서로 다른 설정에서 제안되어 어떤 접근이 작은 모델에서 더 강건한지 비교하기 어렵다.
- 저하 원인 진단의 부족: 성능이 떨어진다는 사실만으로는 정보 자체가 사라진 것인지, 비선형적으로만 남은 것인지 판단하기 어렵다.
- 실용적 결합 연구의 부족: 에이전트 실패 맥락에서 서로 다른 위치와 시간대의 내부 신호를 결합해 작은 모델의 성능을 회복하는 연구는 제한적이다.

따라서 본 연구는 단순히 '소형 모델에서도 프로브가 되는가'를 확인하는 데 그치지 않고, 규모 감소에 따른 신호의 변화 양상, 선형 읽기 가능성의 변화, 그리고 저비용 결합을 통한 회복 가능성을 하나의 실험 설계 안에서 연결한다.

II. 선행연구 검토

1. 에이전트 최종 실패의 조기 예측

Ruan 등(2026)의 Doomed from the Start는 다단계 에이전트가 실패 궤적에 진입한 뒤에도 계속 추론 자원을 소비하는 문제를 대상으로 한다. 각 상호작용 라운드의 hidden activation으로 최종 episode failure를 예측하는 경량 프로브를 학습하고, 라운드별 gate를 cascade 형태로 구성한다. 특히 성공 가능 episode를 잘못 중단하지 않도록 episode-level recall을 통제한다는 점에서 단순 분류 문제를 실제 실행 정책으로 연결한다.

2. 시간적 개념 프로빙

Padhi 등(2026)은 단계별 reward modeling과 conformal prediction을 이용해 에이전트의 내부 표현을 성공, 실패, reasoning drift와 연결되는 시간적 개념으로 라벨링하고, linear probe를 통해 이 방향을 추출한다. ALFWorld와 ScienceWorld에서 시간에 따라 변화하는 latent concept의 선형 분리 가능성을 분석했다는 점에서, 최종 라벨만 보는 정적 프로브와 다른 정보 구조를 제공한다.

3. 모델 규모와 다층 프로브

Nordby 등(2026)은 12개 모델, 0.5B~176B 범위에서 linear probe accuracy가 모델 규모와 함께 증가하는 경향을 보고했으며, 특정 계층 하나에 의존하는 프로브보다 여러 계층의 예측을 결합한 앙상블이 실패 조건을 완화할 수 있음을 보였다. 이 결과는 '작은 모델일수록 내부 신호가 약해질 수 있다'는 본 연구의 가설을 뒷받침하지만, 대상이 다단계 에이전트의 최종 실패가 아니므로 직접적인 일반화 여부는 별도 검증이 필요하다.

4. 도구 필요성 프로브와 본 연구 범위

Sun 등(2026)의 When2Tool 연구는 생성 직전 내부 표현에서 '도구 호출 필요성'이 높은 AUROC로 선형 복호화될 수 있음을 보였다. 그러나 예측 대상은 task failure가 아니라 tool necessity이다. 따라서 본 연구에서는 이를 핵심 비교군으로 직접 재구현하지 않는다. 필요할 경우 향후 확장 실험에서 action 직전 representation의 보조 신호로만 검토하며, 주 실험의 세 방법론은 실패 예측 문제와 직접 연결되는 라운드·시간·계층 축으로 한정한다.

구분	기존 연구의 도달점	본 연구의 공백/확장
모델 규모	3B 포함 일부 검증 또는 타 도메인 scaling 분석	Qwen2.5 단일 계열 0.5B·1.5B·3B 체계 비교 + 7B 참조
비교 범위	각 probing 접근이 서로 다른 프로토콜에서 제안	동일 trajectory·split·metric 아래 직접 비교
진단 수준	주로 판별 성능 또는 시각화 중심	linear vs nonlinear decoding + 표현 기하 통계
결합 방식	다층 결합 효과는 타 도메인에서 확인	에이전트 실패 맥락의 시간·계층 신호 결합
배포 관점	중대형 모델 또는 제한적 소형 실험	저자원 장치에서 재현 가능한 감시 비용과 절감 효과 분석

III. 연구 목적 및 연구 문제

1. 연구 목적

본 연구의 목적은 에이전트 과제 실패와 관련된 내부 표현 신호가 실제 배포 가능한 소형 모델 범위에서 어느 정도 유지되는지를 정량화하고, 성능 저하가 발생할 경우 그 원인을 선형 읽기 가능성 관점에서 진단한 뒤, 추가 추론 비용이 작은 결합 전략으로 성능과 신뢰도를 회복할 수 있는지 검증하는 데 있다.

2. 연구 문제

- 에이전트 과제 실패와 관련된 내부 표현 신호의 예측 가능성은 0.5B~3B 범위에서 모델 규모 감소에 따라 어떻게 변화하며, probing 전략별 scale sensitivity에는 어떤 차이가 존재하는가?

- 소형 모델에서 관찰되는 probe 성능 저하는 실패 관련 정보 자체의 약화로 설명되는가, 아니면 해당 정보의 선형 decodability 저하로 설명되는가?
- 서로 다른 계층·시간 위치에서 추출한 실패 예측 신호를 경량 결합하면, 소형 모델에서 단일 probe 대비 예측 성능과 확률 보정(calibration)을 유의미하게 회복할 수 있는가?

3. 연구 가설

- H1. 모델 규모가 감소할수록 최종 실패 예측 AUROC/AUPRC가 전반적으로 저하되지만, 저하 폭은 probing 전략에 따라 다를 것이다.
- H2. 일부 소형 모델에서는 linear probe가 크게 저하되더라도 소형 MLP probe가 상대적으로 높은 성능을 유지하여 비 선형 decodability가 남아 있을 것이다.
- H3. 단일 계층·단일 시점보다 다층 또는 시간적 신호를 결합한 앙상블이 0.5B~1.5B 구간에서 더 큰 상대적 이득을 보일 것이다.

IV. 연구 방법

1. 연구 설계 개관

연구는 Pilot, Scaling Evaluation, Representation Diagnosis, Lightweight Recovery, Robustness의 다섯 단계로 구성한다. Pilot 단계에서 각 모델의 ALFWorld 기본 성공률과 trajectory 분포를 측정하고, Scaling Evaluation에서 세 probing 전략을 비교한다. 이후 선형·비선형 probe 및 표현 통계를 이용해 저하 원인을 진단하고, 마지막으로 다층·시간 결합을 적용해 성능 회복 여부를 평가한다.

단계	목적	핵심 작업
0	Pilot	모델별 성공률, 평균 step, invalid action, 처리 속도, 메모리 사용량 확인
1	Scaling	0.5B~1.5B~3B에서 동일 조건의 프로브 성능 비교, 7B 참조점 가능
2	Diagnosis	linear vs 2-layer MLP, Fisher ratio, centroid distance, effective rank, layer stability
3	Recovery	다층 평균/가중 결합, temporal stacking, validation 기반 meta-classifier
4	Robustness	seed, layer, task category, 4-bit quantization 영향 및 주요 ablation

2. 실험 환경 및 대상 모델

주 실험 환경은 ALFWorld로 설정한다. ALFWorld는 텍스트 기반 상호작용이 가능하고 환경이 episode 성공 여부를 명확한 이진 라벨로 제공하므로 별도의 인적 라벨링이 필요하지 않다. 또한 시간적 프로브 관련 선행연구에서 사용된 환경이므로 결과 해석과 방법론 적용이 용이하다.

대상 모델은 Qwen2.5-Instruct 단일 계열의 0.5B, 1.5B, 3B를 필수 대상으로 한다. 동일 계열을 사용함으로써 아키텍처와 사전학습 계열 차이가 모델 규모 효과와 교락되는 것을 최소화한다. Qwen2.5-0.5B, 1.5B, 3B의 hidden size와 layer 수가 서로 다르므로 절대 layer 번호를 고정하지 않고 전체 깊이에 대한 상대 위치(예: 25%, 50%, 75%, final)를 기준으로 representation을 추출한다. 7B는 선행연구와의 연결을 위한 상한 참조점으로 두되, 장치 자원과 수행 시간에 따라 축소 표본으로 운영한다.

모델	규모	Hidden size	Layers	역할
Qwen2.5-0.5B-Instruct	0.5B	896	24	필수: 최저 규모
Qwen2.5-1.5B-Instruct	1.5B	1536	28	필수: 중간 규모
Qwen2.5-3B-Instruct	3B	2048	36	필수: 상위 소형 모델

모델	규모	Hidden size	Layers	역할
Qwen2.5-7B-Instruct	7B	참조	참조	선택/참조: 선행연구 연결

3. 행동 정책 및 통제 조건

- 모든 모델에 동일한 ReAct 형식의 system/user prompt template을 적용한다.
- 동일 ALFWorld task instance 목록, 동일 초기 상태, 동일 max steps를 사용한다.
- 주 분석은 가능한 한 deterministic decoding(temperature 0 또는 이에 준하는 설정)을 사용한다.
- 정책 모델 자체는 fine-tuning하지 않고, hidden representation에서 읽히는 실패 신호만 분석한다.
- 모델별 기본 성공률, 평균 episode 길이, invalid action 비율, 반복 행동 비율을 함께 보고하여 trajectory distribution 차이를 통제·해석한다.

4. 비교할 probing 전략

약칭	핵심 아이디어	본 연구 구현	비고
P-Round	라운드별 hidden state로 최종 실패 예측	각 interaction round의 지정 representation에 logistic probe 학습	Ruan et al.에서 영감
P-Temporal	단계별 성공/실패 방향의 시간적 변화	conformal labeling을 포함한 full variant + 단순화 variant 비교	Padhi et al. 기반
P-MultiLayer	여러 계층 probe 결합	상대적 25/50/75/final layer의 개별 probe와 평균·가중 결합	Nordby et al. 접근을 실패 예측에 적용

본 연구는 위 세 접근을 '원 논문의 완전한 동일 재현'이라고 주장하지 않고, 각 선행연구의 핵심 probing principle을 동일한 ALFWorld failure-prediction protocol에 맞게 재구성한 비교 프레임워크로 정의한다. 원 저자 코드가 제공되는 경우 가능한 부분은 그대로 활용하고, adaptation이 필요한 부분은 별도 문서화한다.

5. Hidden representation 추출 규칙

재현성을 위해 hidden state의 위치를 명시적으로 고정한다. 기본 표현은 각 에이전트 step에서 action을 생성하기 직전의 마지막 입력 token에 대한 post-residual hidden state로 정의한다. 모델별 계층 수 차이를 고려해 전체 깊이의 25%, 50%, 75%, final layer에 해당하는 representation을 저장한다. 추가 ablation에서는 action 첫 token 생성 직후 representation 또는 step 내 mean pooling을 비교할 수 있으나, 주 결과는 하나의 기본 정의를 유지한다.

6. 데이터 수집 절차

고정된 episode 수만 수집하면 작은 모델의 낮은 성공률 때문에 성공 사례가 지나치게 적어질 수 있다. 따라서 모델별 최소 300 episode를 기본으로 하되, 성공·실패 각 클래스가 충분히 확보되지 않는 경우 최대 800 episode까지 적응형으로 추가 수집한다. 목표는 전체 평가가 가능한 최소 클래스 표본을 확보하는 것이며, 특정 모델에서 성공 episode 확보가 구조적으로 어렵다면 해당 사실을 base policy limitation으로 명시하고 confidence interval을 넓게 보고한다.

- task instance를 먼저 train/validation/test로 분리하고 동일 instance가 다른 split에 중복되지 않도록 한다.
- 동일 episode의 여러 step은 반드시 같은 split에 속하도록 하여 step-level leakage를 방지한다.
- 권장 split은 task instance 기준 60/20/20이며, 데이터가 적을 경우 repeated group split 또는 group k-fold를 보조적으로 사용한다.

- 각 step마다 episode id, task id, round, action, success label, selected layer hidden state, model metadata를 저장한다.
- 프로브 학습은 episode 또는 task grouping을 유지한 상태에서 수행한다.

7. 평가 지표

지표	목적	해석
AUROC	전반적 판별력	규모·방법론 간 비교의 기본 지표
AUPRC	불균형 데이터 판별력	작은 모델의 성공/실패 불균형에서 핵심
Precision @ fixed Recall	조기 중단 실용성	성공 episode 보존 조건에서 실패 판정의 정확도
Recall @ fixed false-abort	운영 안전성	정상/성공 가능 episode를 잘못 중단하는 비율 통제
Brier score / ECE	확률 보정	앙상블이 '신뢰도'를 실제로 개선하는지 확인
Inference saving	조기 중단 효과	중단 정책 적용 시 절감되는 생성 step/token 비율
Probe overhead	추가 비용	hidden extraction·probe inference로 증가한 시간/메모리

8. 저하 원인 진단 방법

연구문제 2는 단순 시각화만으로 결론 내리지 않는다. 각 representation에 동일한 train/validation/test split을 사용해 linear logistic probe와 제한된 용량의 2-layer MLP probe를 함께 학습한다. linear 성능은 낮지만 MLP가 유지되는 경우 실패 관련 정보가 완전히 사라진 것이 아니라 선형 decodability가 저하된 것으로 해석한다. 두 모델 모두 저하될 경우에는 representation 자체의 정보 약화를 시사하는 증거로 본다.

- Fisher discriminant ratio: class 간 분리 대비 class 내 분산을 비교한다.
- Centroid distance 및 within/between-class distance ratio를 계산한다.
- Effective rank 또는 participation ratio로 표현 차원의 사용 구조를 비교한다.
- Probe weight 방향의 seed 간 cosine similarity로 학습 안정성을 평가한다.
- PCA/t-SNE는 정성적 시각화용으로만 사용하며, 인과적 결론의 근거로 사용하지 않는다.

Linear probe	2-layer MLP	해석
높음	높음	실패 관련 정보가 선형적으로도 충분히 존재
낮음	높음	정보는 존재하지만 선형 decodability가 약화
낮음	낮음	현재 representation에서 실패 정보 자체가 약하거나 표본이 부족
높음	낮음	학습/정규화 설정 이상 여부를 우선 점검

9. 경량 결합 설계

결합안	설계	학습/누수 통제
E1 단순 평균	여러 layer/temporal probe의 probability 평균	추가 학습 없음
E2 Validation 가중	validation AUROC/AUPRC 또는 calibration 기반 가중치	test 정보 사용 금지
E3 Stacking	base probe probability를 입력으로 logistic meta-classifier 학습	out-of-fold 또는 validation prediction만 사용
E4 Majority vote	이진 판정 결과의 단순 다수결	threshold는 validation에서 결정

핵심 비교 기준은 각 규모에서 가장 좋은 단일 probe와 결합안의 차이이다. 특히 작은 모델에서 absolute gain뿐 아니라 relative error reduction을 함께 보고하여 '양상불 이득이 소형 규모에서 확대되는가'를 검증한다.

10. 통계 검증

- 주요 결과는 최소 5개 random seed 평균과 95% confidence interval로 보고한다.
- AUROC/AUPRC 차이는 episode 또는 task instance 단위 paired bootstrap으로 평가한다.
- 가능한 경우 AUROC에는 DeLong test를 보조적으로 사용하되, 반복 step의 비독립성을 고려해 bootstrap 결과를 우선 해석한다.
- ensemble vs best single 비교는 동일 test episode에 대한 paired resampling으로 수행한다.
- 다중 비교가 많아질 경우 Holm 보정 등 간단한 family-wise correction을 적용한다.

11. Quantization 및 장치 조건 검증

개인용 Apple Silicon 16GB 환경에서 실험하기 위해 4-bit quantization을 주로 활용할 수 있으나, 본 연구의 핵심 관심 이 hidden-state geometry인 만큼 quantization 자체가 표현 구조를 바꾸는 교란 요인이 될 수 있다. 따라서 가능한 모델 1종(우선 1.5B 또는 3B)에서 BF16/FP16과 4-bit 조건을 소규모로 비교해 주요 probe 지표가 크게 달라지지 않는지 sanity check를 수행한다. 차이가 유의하면 본 실험은 'quantized deployment setting에서의 scale effect'로 해석 범위를 제한한다.

V. 연구 수행 여건 및 실현 가능성

0.5B~3B 모델의 inference와 선형·소형 MLP probe 학습 자체는 16GB Apple Silicon 장치에서 수행 가능한 범위로 예상된다. 다만 실제 총 소요 시간은 episode 길이, decoding backend, hidden-state 저장 방식, quantization 구현에 따라 크게 달라질 수 있으므로 특정 시간 값을 사전에 확정하지 않는다. 1주차 Pilot에서 models/sec, tokens/sec, peak memory, episode당 평균 시간을 측정한 뒤 전체 수집량을 확정한다.

작업	자원 요구	운영 원칙	Fallback
0.5B~3B 궤적 수집	16GB 단일 장치	순차 실행·hidden state 즉시 디스크 저장	episode 상한 조정
7B 참조 실험	4-bit 중심	축소 표본·선택 실행	미수행 시 기존 7B 연구와 문헌 비교
Linear/MLP probe	CPU/GPU 소규모	모델별·계층별 독립 학습	특징 차원 축소
Stacking	CPU 소규모	out-of-fold probability 사용	단순 평균으로 대체
시각화/통계	CPU	저차원 요약 후 분석	t-SNE 생략 가능

몬테카를로 대규모 rollout, 수천~수만 episode의 exhaustive sweep, 여러 환경·여러 모델 계열을 동시에 비교하는 설계는 본 연구 범위에서 제외한다. 이는 연구의 제약이지만, 동시에 저자원 환경에서 재현 가능한 실험 설계라는 실용적 성격을 명확히 한다.

VI. 예상 결과 및 기대효과

1. 예상 결과

모델 규모가 감소함에 따라 실패 예측 성능이 전반적으로 낮아질 가능성이 있으나, 라운드·시간·계층 기반 probing 전략의 저하 폭은 동일하지 않을 것으로 예상된다. 특히 단일 계층 probe가 작은 모델에서 불안정해질 경우 다층 결합이 상대적으로 큰 이득을 줄 수 있다. 또한 linear probe와 MLP probe 사이의 격차가 규모에 따라 증가한다면, 단순한 '정보 소실'이 아니라 representation geometry의 비선형화라는 설명을 제시할 수 있다.

반대로 모든 probe와 MLP가 동시에 낮아지고 앙상블도 회복 효과를 보이지 않는다면, 작은 모델에서는 최종 실패와 관련된 내부 신호 자체가 충분히 형성되지 않는다는 결과가 된다. 이 역시 내부 표현 기반 감시가 신뢰 가능한 최소 규모를 정하는 실질적인 부정 결과로 가치가 있다.

2. 기대효과

- 학술적 효과: 에이전트 failure signal의 sub-3B scale sensitivity를 동일 모델 계열에서 정량화한다.
- 방법론적 효과: 서로 다른 probing principle을 동일 protocol에서 비교할 수 있는 재현 프레임워크를 제공한다.
- 해석적 효과: 성능 저하를 정보 약화와 선형 decodability 저하로 구분하는 분석 기준을 제시한다.
- 실용적 효과: 온디바이스·저비용 에이전트에서 내부 표현 감시를 적용할 수 있는 규모와 비용의 판단 근거를 제공한다.
- 재현성 효과: trajectory 수집, hidden extraction, grouped split, probe/ensemble 평가 코드를 공개한다.

VII. 연구의 한계 및 대응

예상 한계	대응 방안
새로운 프로브 아키텍처 제안이 아니라 기존 원리의 비교·재구성이라는 지적	기여를 sub-3B systematic evaluation, representation diagnosis, reproducible benchmark로 명확히 규정한다.
원 논문과 환경·예측 대상이 완전히 동일하지 않음	완전 재현이 아닌 adaptation임을 명시하고, 가능한 부분의 sanity check 및 구현 차이를 공개한다.
ALFWorld 단일 환경의 외적 타당도	주 결과의 범위를 ALFWorld interactive task로 제한하고, 여유 시 ScienceWorld 소규모 확장을 실시한다.
단일 모델 계열로 인한 일반화 제약	규모 효과 통제를 위한 의도적 설계임을 밝히고, 후속 연구에서 타 계열 검증을 제안한다.
0.5B 모델의 낮은 성공률로 class imbalance 심화	적응형 episode 수집, AUPRC, grouped bootstrap, 넓은 CI를 사용하고 성공률 자체도 결과로 보고한다.
4-bit quantization의 표현 교란 가능성	1개 모델에서 BF16/FP16 vs 4-bit sanity check를 수행하고 해석 범위를 명확히 한다.

VIII. 최종 산출물 및 성공 기준

1. 최종 산출물

- Qwen2.5 0.5B~3B ALFWorld trajectory 및 split metadata
- 세 probing 전략의 통일 구현 코드와 설정 파일
- linear/MLP representation diagnosis 모듈
- ensemble 및 calibration 평가 코드
- 규모별 AUROC/AUPRC/calibration/inference-saving 비교표
- 재현 절차를 포함한 논문 초안 및 공개 가능한 benchmark repository

2. 최소 성공 기준

연구의 성공을 특정 가설이 반드시 맞는 것으로 정의하지 않는다. 최소 성공 기준은 (1) 0.5B·1.5B·3B에서 동일 protocol의 실패 예측 데이터를 확보하고, (2) 최소 두 종류 이상의 probing 전략과 linear/nonlinear control을 동일 split에서 평가하며, (3) 규모 감소에 따른 성능 차이와 95% confidence interval을 보고하고, (4) 결합이 효과적이든 아니든 그 결과를 데이터 누수 없이 검증하는 것이다. 따라서 '양상불이 회복에 실패한다'는 결과도 연구질문에 대한 유효한 결론으로 취급한다.

참고문헌

- Nordby, E., Pais, T., & Parrack, A. (2026). Linear Probe Accuracy Scales with Model Size and Benefits from Multi-Layer Ensembling. arXiv:2604.13386.
- Padhi, T., Kaur, R., Agarwal, K., Cobb, A. D., Elenius, D., Acharya, M., Samplawski, C., Berenbeim, A. M., Bastian, N. D., Jha, S., & Roy, A. (2026). From Actions to Understanding: Conformal Interpretability of Temporal Concepts in LLM Agents. arXiv:2604.19775.
- Ruan, K., Huang, Z., Zhou, Z., Wei, Q., Wang, X., & Sun, H. (2026). Doomed from the Start: Early Abort of LLM Agent Episodes via a Recall-Controlled Probe Cascade. arXiv:2607.06503.
- Shridhar, M., Yuan, X., Côté, M.-A., Bisk, Y., Trischler, A., & Hausknecht, M. (2021). ALFWorld: Aligning Text and Embodied Environments for Interactive Learning. ICLR.
- Sun, C.-E., Liu, L., Yan, G., Wang, Z., & Weng, T.-W. (2026). LLM Agents Already Know When to Call Tools — Even Without Reasoning. arXiv:2605.09252.
- Qwen Team. Qwen2.5 model configuration files and model cards for Qwen2.5-0.5B-Instruct, Qwen2.5-1.5B-Instruct, and Qwen2.5-3B-Instruct. Hugging Face.